데이터 증강 및 대조학습 기반의 의료 이미지 분할 방법

이윤지 O,1, 장수진 2, 윤정민 3, 김영빈 2,3
1 중앙대학교 응용통계학과, 2 중앙대학교 첨단영상대학원, 3 중앙대학교 AI 학과
pioneer0305@cau.ac.kr, sujin0110@cau.ac.kr, cocoro357@cau.ac.kr, ybkim85@cau.ac.kr

요 약

의료 영상 분할은 CT 또는 MRI 영상에서 장기나 종양을 구분하는 기술을 의미한다. 딥러닝 기반의 의료 이미지 분할은 고품질의 라벨링 데이터를 필요로 하지만, 이는 검증된 픽셀 단위의 라벨링을 필요로 하여 많은 시간과 비용이 소모된다. 더불어 의료 이미지는 동일한 촬영기기로 동일 부위를 촬영하므로 데이터 간의 유사성이 높은 특징이 있다. 이에 본 연구에서는 의료 이미지의 적은 데이터와 다양성 부족 문제를 완화하고자, 효과적인 데이터 증강을 위한 실험을 진행하여 의료 이미지에 적합한 데이터 증강 기법을 분석한다. 또한, 이미지 간 상대적 거리를 고려하여 유사성과 차별성을 학습하는 대조학습 기반의 이미지 분할 모델을 제안한다. 이를 통해 제안하는 방법은 이미지 내의 차별적인 특징을 효과적으로 학습할 수 있다. Synapse 데이터셋을 이용한 이미지 분할 예측 실험 결과, 기존 모델 대비 DSC 가 1.58 상승하고 HD 가 12.71 하락하여 제안하는 방법이 우수한 분류 성능을 달성한다는 것을 확인하였다.

1. 서론

딥러닝 기술의 발전에 따라 의료 분야에서는 질병 분류(disease classification), 의료 이미지 등록(medical image registration), 의료 객체 탐지(medical object detection)와 같은 다양한 분야에서 딥러닝 기술이 활용되고 있다[1,2]. 특히 의료 이미지 분할(medical image segmentation)은 컴퓨터 도움 진단(computer-aided diagnosis)과 병리학 연구에서 중요한 역할을 하며 지속적인 발전이 이루어지고 있다. 그러나 의료 이미지 분할은 고품질의 라벨링 데이터를 생성하기 위해 전문가의 도메인 지식을 필요로 하며 픽셀 단위의 라벨링은 많은 시간과 비용을 요구한다[3]. 또한, 의료 이미지 데이터의 활용에는 두 가지 제한 사항이 존재한다. 첫 번째로, 특정 질병군 환자의 수가 부족하여 데이터의 양이 충분하지 않은 경우가 많다. 또한, 환자의 프라이버시 문제로 인해 데이터의 수집 및 이용이 어렵다[4]. 두 번째로, 의료 촬영 기기와 기법의 표준화로 환자별 촬영 이미지가 유사한 양상을 보인다[5]. 이러한 데이터 간 높은 유사성으로 인해 각 이미지마다 차별성 있는 특성을 학습하는데 어려움이 발생한다.

최근 데이터 부족 문제에 대응하기 위한 방법 중 하나로 대조학습(contrastive learning)을 활용한 다양한 연구들이 제안되었다[6]. 대조학습은 주어진 데이터에 대하여 긍정 쌍(positive pair)과의 유사도를 최대화하고 부정 쌍(negative pair)에 대해 유사도를 낮추는 형태로 데이터를 표현하며 이미지 내의 차별적인 특징을 학습할 수 있다. SimCLR[7]은 이미지 분류 작업에 대해 데이터 증강을 통해 긍정 쌍과 부정 쌍을 구성하여 대조 학습을 수행하는 방법을 제안하였다. 또한 단일 기법이 아닌 여러 증강 기법을 통합하여 데이터의 표현 학습과 일반화 효과를 입증하였다. 의료분야에서도 이러한 대조학습을 적용한 연구들이 제안되었다[8]. 해당 연구에서는 동일한 레이블에 속하는 이미지를 긍정 쌍으로 설정하고, 다른 레이블에 해당하는 이미지를 부정 쌍으로 설정한다. 이에 대한 대조학습을 통해 같은 레이블에 속하는 데이터 간 공통된 표현을 효과적으로 학습한다. 그러나 이러한 방식은 동일 레이블 내의 각 이미지의 차별적인 표현을 학습하지 못하는 한계가 있다.

본 논문에서는 의료 이미지 데이터의 부족과 유사성으로 인한 문제를 완화하기 위해 대조학습 기반의 의료 이미지 분할 방법을 제안한다. 제안하는 방법은 트랜스포머(transformer)[9] 기반의 모델을 활용하여 이미지 내의 전역적인 의미론적 특징(long-range semantic feature)을 포착할 수 있다. 또한, 대조학습을 활용하여 이미지 내의 유사성과 동시에 차별적인 특징을 효과적으로 학습한다. 이때 실험을 통해 의료 이미지에 적합한 데이터 증강 방법을 분석하고 이를 기반으로 대조학습을 적용함으로써 데이터의 효율성을 향상시키고 의료 이미지에 강건한 모델을 학습할 수 있다.

제안하는 방법은 대조학습에 효과적인 데이터 증강을 위해 공간적 변형(spatial transform)과 픽셀

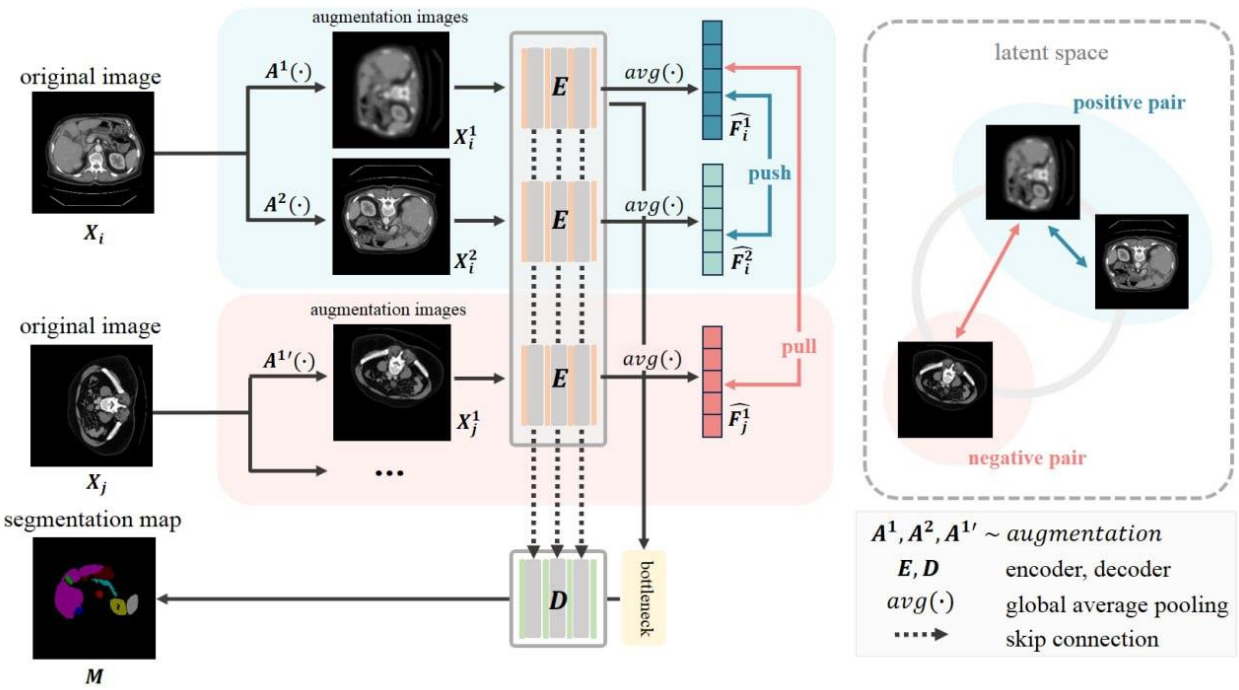

그림 1. 제안하는 이미지 분할 모델 대조 학습 방법

단위의 변형(pixel-level transform)인 gaussian blur, gaussian noise 등의 증강 기법을 적용한다. 이후 동일한 이미지로부터 생성된 증강 이미지를 긍정 쌍으로 설정하여 임베딩 공간 내에서 서로 가까워지도록 학습한다. 이와는 반대로 다른 이미지들은 부정 쌍으로 설정하여 서로 멀어지도록 학습한다. 실험 결과, 제안하는 모델은 Synapse 데이터셋에서 DSC(Dice Coefficient Score)는 77.54, HD(Haudsdorff Distance)는 15.16 을 달성하며 기존 모델 대비 향상된 성능을 보인다. 특히 HD 가 약 12.71 하락하였는데, 이를 통해 정답과 예측 집합 사이의 거리가 가까우며 이상치 없이 모델의 예측이 강건함을 확인할 수 있다. 이에 제안하는 모델이 한정된 주석(annotation) 환경에서 대조학습을 활용하여 각 이미지의 차별적인 특성을 학습하고 더 나은 분할 결과를 도출할 수 있음을 입증한다.

2. 대조 학습을 통한 트랜스포머 기반 이미지 기반 이미지 분할 모델

이 장에서는 본 논문에서 제안하는 대조 학습을 활용한 이미지 분할 모델에 대해 설명한다. 제안하는 방식은 인코더에서 이미지 특징을 추출한 뒤 데이터 증강에 기반한 대조 학습을 통해 이미지별 차별화된 특징을 학습한다. 본 논문에서 제안하는 이미지 분할 모델 대조 학습 방법의 구조는 그림 1 과 같다.

2.1 데이터 증강

본 논문에서는 대조학습을 위한 이미지 긍정 쌍을 생성하기 위해 데이터 증강 기법을 도입한다. 데이터 증강은 데이터의 양을 증가시키고 다양성을 확보하는데 유리하다는 장점을 지닌다. 그러나 모델의 학습 전략과 작업 및 데이터에 적합하지 않은 데이터 증강 기법은 모델의 성능 저하로 이어질 수 있다. 이에 우리는 실험을 통해 의료 이미지 분야에서 적용되는 데이터 증강 기법들에 따른 효과를 검증한다. 특히 대조학습에서 동일한 이미지의 서로 다른 영역을 동일하게 인식하는 오류가 발생할 수 있다[10]. 이에 따라, 공간 변형 및 픽셀 단위의 변형에 기반한 데이터 증강 기법들에 대한 실험을 통해 모델의 분할 성능 변화를 분석한다.

이미지 데이터에 대하여 데이터 증강 집합 Aug 을 기반으로 서로 다른 증강 기법을 적용한다. Aug 는 rotation, horizontal flip, gaussian blur, gaussian noise, sharpen, random brightness contrast 증강 기법으로 구성된다. 원본 입력 이미지 X 에 대하여, 증강 데이터는 다음과 같이 정의한다.

$$X_i^1 = A^1(X_i),\ X_i^2 = A^2(X_i) \tag{1}$$

여기서 $A^1, A^2 \in Aug$ 이며, $A^1(\cdot)$과 $A^2(\cdot)$는 데이터 증강 집합 Aug 의 서로 다른 부분 집합을 나타낸다. i는 배치 내 이미지의 인덱스를 의미한다.

2.2 대조학습

대조학습은 주어진 이미지 X_i에 대해 긍정 쌍 간의 유사도를 최대화하고 부정 쌍에 대한 유사도를 최소화하여 이미지 간 유사성과 차이를 학습한다. 인코더 E 는 한 쌍의 데이터에 대하여 각각의 특징 맵(Feature map) F_i^1, $F_i^2 \in R^{C\times H\times W}$을 생성한다. 이후 global average pooling $avg(\cdot)$을 통해 각 이미지에 대한 전역적인 특징을 추출하며, 이에 대한 수식은 다음과 같이 정의한다.

$$F_i^1 = E(X_i^1),\ F_i^2 = E(X_i^2) \tag{2}$$

$$\widehat{F_i^1} = avg(F_i^1),\ \widehat{F_i^2} = avg(F_i^2) \tag{3}$$

이후, $\widehat{F_i^1}, \widehat{F_i^2}$에 대해 cosine similarity $sim(\cdot)$을 통해 이미지 간 유사도를 계산한다. 이를 기반으로 InfoNCE 손실함수[11]를 적용하며, 손실함수는 다음과 같이 정의한다.

$$sim(u,v) = \frac{u^T v}{\|u\|\|v\|} \tag{4}$$

$$P_i^+ = e^{sim\left(\widehat{F_i^1},\widehat{F_i^2}\right)} \tag{5}$$

$$P_i^- = \sum_{k=1}^{N}\sum_{j=1}^{2} I_{i\neq k}\{e^{sim\left(\widehat{F_i^1},\widehat{F_k^j}\right)/\tau} + e^{sim\left(\widehat{F_i^2},\widehat{F_k^j}\right)/\tau}\} \tag{6}$$

$$\mathcal{L}_{cl} = \sum_{k=1}^{N} - log\frac{2P_i^+}{P_i^+ + P_i^-} \tag{7}$$

여기서 τ는 temperature factor 를 나타낸다. 손실함수가 최소화될수록 두 증강 이미지 간의 유사성은 최대화되며, 이를 통해 유사도가 높은 의료 이미지 간의 차별적인 특징을 효과적으로 학습할 수 있다.

2.3 모델 학습

디코더 D는 F_i^1를 기반으로 분할 맵(segmentation map) M을 생성한다. 이후 분할 맵 M에 대하여 의미론적 분할에 일반적으로 사용되는 cross entropy 손실함수를 적용한다. 추가적으로 기존 연구[12]와 같이 분할 정확도를 고려하기 위해 dice 손실함수[13]를 적용하여, 최종적인 손실함수는 다음과 같이 정의한다.

$$\mathcal{L}_{total} = \lambda_{cl}\mathcal{L}_{cl} + \lambda_{ce}\mathcal{L}_{ce} + \lambda_{dice}\mathcal{L}_{dice} \tag{8}$$

여기서 $\mathcal{L}_{cl}, \mathcal{L}_{ce}, \mathcal{L}_{dice}$ 은 손실함수의 균형을 조절하기 위해 사용된 하이퍼파라미터(hyperparameter)를 나타낸다.

3. 실험 결과 및 분석

3.1 데이터셋

제안하는 방법의 효과를 검증하기 위해 Synapse[14]에서 제공하는 Synapse Abdomen 데이터셋을 사용해 실험을 진행한다. 해당 데이터셋은 30 개의 CT 영상으로 구성되어 있으며, 8 개의 복부 장기를 라벨 정보로 포함한다. 전체 30 개의 케이스는 18 개의 학습 데이터와 12 개의 평가 데이터로 구분된다.

3.2 실험 환경

본 논문에서는 Synapse 데이터셋에 대하여 학습을 진행하였으며, 224 × 224 로 이미지를 resize 한다. 데이터 증강 기법의 집합은 rotation, horizontal flip, gaussian noise, gaussian blur, sharpen, random brightness contrast 을 포함하며, 실험을 통해 제안 방식과 데이터셋에 가장 적합한 조합을 선정하여 사용한다.

제안하는 방법은 Swin-Unet 기반의 구조를 사용하였으며, 학습 시 배치 크기는 24 로 설정한다. 모델 학습을 위한 optimizer 로는 SGD 를 사용한다. 학습률은 0.01 이며, 150 에폭동안 학습을 진행한다. τ는 1.0 으로 설정하였으며, 손실함수에서 사용하는 $\mathcal{L}_{cl}, \mathcal{L}_{ce}, \mathcal{L}_{dice}$는 각각 0.7, 0.4, 0.6 으로 설정한다.

제안하는 방법의 효과를 검증하기 위한 비교 모델로는 R50 U-Net[15], R50 Att-UNet[15], Swin-Unet[11]을 사용한다. 평가지표로는 Dice-Similarity coefficient(DSC)의 평균과 Hausdorff Distance(HD)의 평균을 사용한다.

3.3 실험 결과 및 분석

제안하는 방법에서 대조학습에 따른 효과를 검증하기 위해 기존 모델 Swin-Unet 과의 DSC 와 HD 점수를 비교한다. 기존 모델과 제안하는 방법 간의 분할 성능을 비교한 결과는 표 1 과 같다. 실험 결과, 제안하는 방법은 기존 모델 대비 DSC 가 1.58 상승하고 HD 가 12.71 하락하여, 분할 성능이 향상되는 결과를 확인할 수 있다. 이에, 대조학습을 통해 이미지의 유사성과 차별적 표현을 학습함으로써

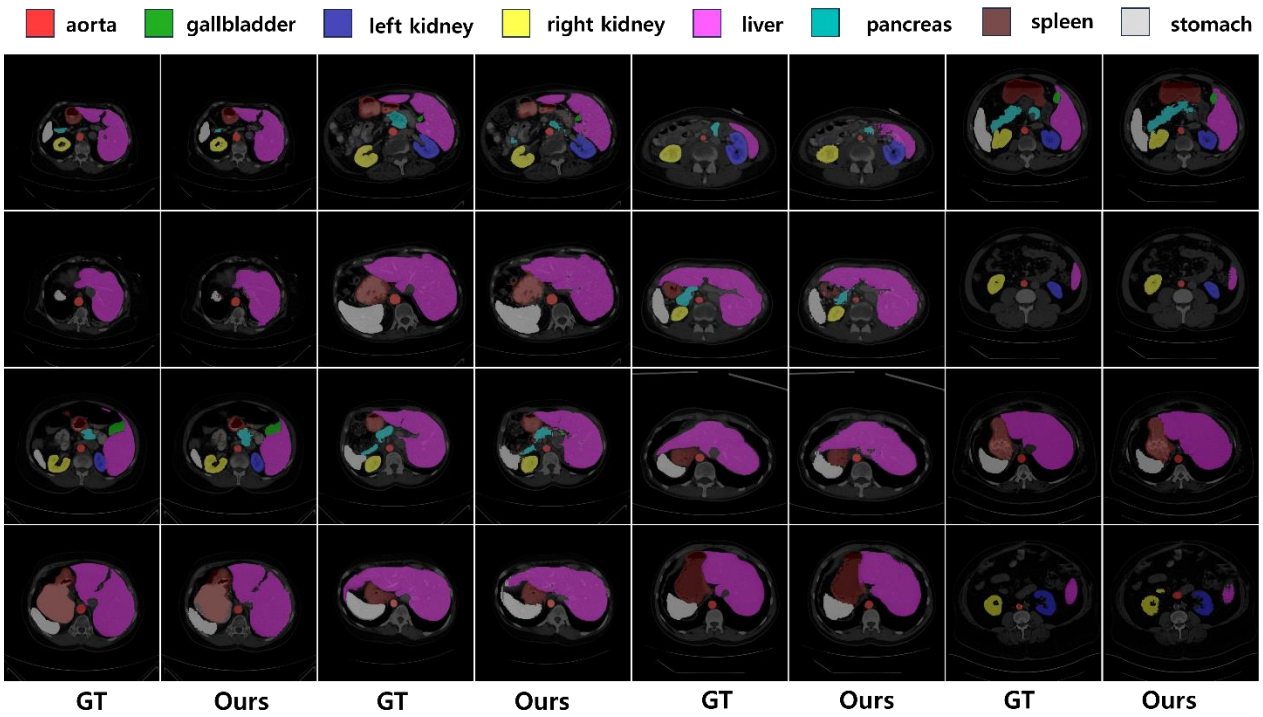

그림 2. 제안한 방법의 예측 분할맵 시각화

레이블에 대한 분포와 영역 차이만을 고려한 기존 방식을 효과적으로 개선하였음을 확인할 수 있다.

표 1. 분할 모델과 제안 모델의 예측결과에 대한 DSC 와 HD 점수비교

Method	score	
	DCS↑	HD↓
R50 U-Net	74.68	36.87
R50 Att-UNet	75.57	36.97
Swin-Unet	75.96	27.73
Ours	**77.54**	**15.16**

또한, 대조 손실함수 가중치 λ_{cl}에 따른 분할 성능을 비교한 결과는 표 2 와 같다. 실험 결과, λ_{cl}가 0.7 에서 DSC 가 0.775, HD 가 15.16 으로 가장 높은 성능을 보인다. 이에 λ_{cl}=0.7 로 설정한다.

표 2. 대조 손실함수 가중치에 따른 점수비교

λ_{cl}	0.5	0.6	0.7	0.8	0.9
DCS↑	77.21	76.76	**77.54**	77.38	77.25
HD↓	13.661	16.787	**15.160**	16.004	15.65

데이터셋과 모델에 적합한 데이터 증강 기법을 분석하기 위한 실험을 진행한다. 데이터 증강 기법의 조합에 따른 DSC 점수를 비교한 결과는 표 3 과 같다. 의료 이미지 분할에서 주로 활용하는 공간적 변형 증강 기법인 rotation 과 픽셀 단위 변형 증강 기법인 gaussian noise (GN), gaussian blur (GB), sharpen, random brightness contrast (RBC) 등의 기법들을 적용하여 실험을 진행한다. 증강 기법들에 따른 성능 실험 결과, rotation, GB, RBC 기법을 적용할 때 74.83 의 DSC 성능을 보인다. 추가적으로 pixel-dropout 증강 기법을 적용하였을 때 76.76 의 DSC 로 향상되었다.

표 3. 데이터 증강 기법에 따른 DSC 점수비교

Rotation	GN	GB	Sharpen	RBC	DSC↑
o	o	o	o	o	72.27
o	x	o	o	o	74.29
o	o	x	o	o	72.13
o	o	o	x	o	73.90
o	x	o	o	x	72.57
o	**x**	**o**	**x**	**o**	**74.83**
o	x	o	x	x	73.9
o	x	x	x	o	73.82

Synapse 데이터셋에 대한 8 개의 장기 레이블에 대한 제안 모델의 분할 결과를 시각화한 결과는 그림 2 과 같다. 제안하는 방법은 각 장기에 대해서 GT 와 유사한 예측 결과를 보이며, aorta 나 gallbladder 와 같이 크기가 작은 장기에 대해서도 뛰어난 영역 분할 결과를 보여준다.

4. 결론

본 논문에서는 데이터 증강 기법을 활용한 대조 학습을 통한 의료 이미지 분할 방법을 제안한다. 증

강된 데이터를 활용하여 모델의 인코더를 거쳐 동일 이미지에서 추출된 특징들 간의 잠재 공간 내 거리를 최소화하고, 다른 특징들 간의 거리를 최대화하도록 학습한다. 이를 통해 이미지 간의 유사성과 차별성을 효과적으로 학습할 수 있다. 또한, 대조학습과 모델 및 데이터셋에 적합한 데이터 증강 기법을 분석하여 제안 방법에 도입한다. 기존 연구에서 활용된 데이터 증강 기법들을 다양하게 조합하여 평가한 결과, 최적의 DSC 성능을 보인 조합을 선택한다. 더불어, 의료 이미지 분할에서 효과를 보인 데이터 증강 기법들이 대조학습을 적용하는 모델에서는 성능 하락을 초래할 수 있음을 분석하였다. 또한, 예측과 레이블 간의 분포 영역 차이만을 고려하는 기존 손실함수를 개선하였다. 제안한 방법의 효과를 검증하기 위한 실험 결과, 기존 방법 대비 DSC 가 약 1.58 상승하고 HD 가 약 12.577 감소함을 확인할 수 있었다. 이를 통해 자기지도 학습에서 주로 사용되던 대조학습 방식이 지도 학습에서도 효과적으로 이미지의 표현을 학습하고 분할 성능을 향상시킬 수 있음을 입증하였다. 향후 연구에서는 데이터 증강과 함께, 동일 위치의 이미지 슬라이스를 긍정 쌍으로 활용하는 대조학습을 결합한 이미지 분할 모델을 설계하고자 한다. 이를 통해 높은 성능과 안정성을 갖춘 의료 이미지 분할 모델을 발전시키는 것을 목표로 한다.

감사의 글

이 논문은 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원(NRF-2022R1C1C1008534)을 받아 수행된 연구임.

참고문헌

[1] M.Kim, J.Yun, Y.Cho, K. Shin, R. Jang, H. J. Bae, and N. Kim, “Deep learning in medical imaging,” Neurospine, vol. 16, no. 4, pp. 657, 2019.

[2] W. Zhu, A. Myronenko, Z. Xu, W. Li, H. Roth, Y. Huang, and D. Xu, “Neurreg: Neural registration and its application to image segmentation,” In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, pp. 3617-3626, 2020.

[3] A. Taleb, C. Lippert, T. Klein, and M. Nabi, “Multimodal self-supervised learning for medical image analysis,” In International conference on information processing in medical imaging, pp. 661-673, 2021.

[4] A. L. Simpson, M. Antonelli, S. Bakas, M. Bilello, K. Farahani, B. Van Ginneken, and M. J. Cardoso, “A large annotated medical image dataset for the development and evaluation of segmentation algorithms,” arXiv preprint arXiv:1902.09063, 2019.

[5] 이승은, 강경태, “의료 영상 분할에서의 강건성 향상 연구: 입력 변환 방법을 통한 적대적 노이즈 제거,” 정보과학회논문지, 제 50 권, 제 10 호, pp. 859-865, 2023, 2023.

[6] S. Shurrab and R. Duwairi, “Self-supervised learning methods and applications in medical imaging analysis: A survey,” PeerJ Computer Science, vol. 8, e1045, 2022.

[7] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” International conference on machine learning, pp. 1597-1607, 2020.

[8] X. Hu, D. Zeng, X. Xu, and Y. Shi, “Semi-supervised contrastive learning for label-efficient medical image segmentation,” Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Proceedings, Part II 24, pp. 481-490, 2021.

[9] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, and I. Polosukhin,"Attention is all you need," Advances in neural information processing systems, vol. 30, 2017.

[10] J. Zhang and K. Ma, “Rethinking the augmentation module in contrastive learning: Learning hierarchical augmentation invariance with expanded views,” In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 16650-16659, 2022.

[11] A. V. D. Oord, Y. Li, and O. Vinyals, “Representation learning with contrastive predictive coding,” arXiv preprint arXiv:1807.03748, 2018.

[12] H. Cao, Y. Wang, Y., J. Chen, D. Jiang, D., X. Zhang, Q. Tian, and M. Wang, “Swin-unet: Unet-like pure transformer for medical image segmentation,” In European conference on computer vision, pp. 205-218, 2022.

[13] C. H. Sudre, W. Li, T. Vercauteren, S. Ourselin, and M. Jorge Cardoso, "Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations," Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: Third International Workshop, DLMIA 2017, and 7th International Workshop, ML-CDS 2017, Proceedings vol.3, pp. 240-248, Springer International Publishing, 2017.

[14] B. Landman, Z. Xu, J. Igelsias, M. Styner, T. Langerak and A. Klein, “Miccai multi-atlas labeling beyond the cranial vault–workshop and challenge,” Proc. MICCAI Multi-Atlas Labeling Beyond Cranial Vault—Workshop Challenge, proceeding vol.5, p.12, 2015.

[15] J. Chen, Y. Lu, Q. Yu, X. Luo, E. Adeli, Y. Wang, and Y. Zhou, “Transunet: Transformers make strong encoders for medical image segmentation,” arXiv preprint arXiv:2102.04306, 2021.