Journal of the Korean Data Analysis Society (February 2023), 25(1), 417-429.
https://doi.org/10.37727/jkdas.2022.25.1.417

학습경로 생성을 위한 잠재된 학습 콘셉트의 선후관계 분석 : 구조방정식과 HMM을 이용하여*

최현희[1], 이윤지[2]

요 약

비대면 학습을 활용하는 빈도가 높아지면서, 효율적인 학습을 위해 적응형 학습에 관한 관심이 높아지고 있다. 학생들이 주어진 학습을 쉽게 하려면, 학생들의 학습 성과를 고려한 학습경로의 설정이 필요하다. 그러나, 현존하는 대부분의 학습경로는 학습 로그에 기반해서 만들어지기보다는 경험 많은 교사들이 사용해온 커리큘럼에 의존하여 만들어진다. 그러나, 현재의 학생들이 이러한 커리큘럼 체계를 통하여 효율적으로 학습할 수 있는가에 대한 답은 확실하지 않다. 본 연구는 기존에 발표된 데이터를 이용하여 학습경로를 생성했던 연구에 더해 구조방정식 모형을 이용하고 hidden Markov model(HMM)과 귀납 논증을 활용하여 한 단계 높은 수준의 잠재 요인 간의 학습경로를 생성하는 데에 중심을 두고 있다. 2020년 D사의 수학 학습데이터를 이용하여, 세분된 학습 개념들의 학습경로가 아닌 세분된 개념들이 그룹화되어 생성된 상위 개념들의 학습경로를 생성하였고, 그룹화에 사용된 세분된 개념들의 신뢰성 및 타당성을 확인하였다. 세분된 개념들은 상위 개념에 대하여 신뢰성 있는 관측값을 보여주었으며 개념이 전달하려는 내용을 세분된 개념들이 타당성 있게 전달하는 것으로 확인되었다.

주요용어 : 학습경로, 구조방정식 모형, hidden Markov model(HMM), 귀납 논증.

1. 서론

‘적응형 학습(adaptive learning)’이란 학습자의 수준에 맞게 학습법과 학습량을 조절할 수 있는 이러닝(e-learning)과 관련한 용어이다. 최근 COVID19와 같은 사회적 이슈로 인하여 Cha(2022)에서 언급한 바와 같이 개개인의 생활 방식이 바뀌고, 비대면 학습을 활용하는 빈도가 높아지면서 이 용어는 우리의 일상생활과 매우 가깝게 자리 잡았다. 예로, World Education Forum(2020)에서 4차 산업과 연계되어 첨단 기술과 자동화를 통해 새로운 교육의 패러다임을 제시하는 학습기법인 “Education 4.0”을 위한 틀이 소개되었을 뿐 아니라, 인공지능과 빅데이터가 교육에 깊숙이 적용되면서 적응형 학습은 온라인 교육의 새로운 핫스팟이 되었다. 특히, Li, He, Xue(2021)에서는 미국의 Knewton, 한국의 Knowre, 호주의 Smart Sparrow등 현존하는 적응형 학습 시스템을 소개하였다. 이들의 주요 기술은 지식의 매핑(knowledge mapping)을 포함하는데, adaptive learning이 가능하기 위해서는 지식의 매핑을 이용한 최적화된 학습경로가 설정되어 있어야 함을 언급한다.

---

*본 논문은 ㈜대교의 지원을 받아 수행된 연구임
[1](교신저자) 06633 서울 서초대로 54길 29-30, 라이브데이터(주) 수석연구원. Email: choihh@laivdata.com
[2]06974 서울 동작구 흑석로 84, 중앙대학교 응용통계학과 학부재학생. E-mail: pioneeryjlee@laivdata.com
[접수 2022년 11월 30일; 수정 2022년 12월 20일; 게재확정 2022년 12월 31일]

학습경로는 노드(node)들을 구성하는 기본적인 지식 콘텐츠의 단위 즉, knowledge concept(KC, 예: 5 이하의 곱셈, 분자가 1인 분수)으로 구성되어있다. KC에 대한 이름은 학습 플랫폼마다 다르다. 에듀테크 공공 서비스인 Assistments(https://new.assistments.org/)에서는 지식 콘텐츠의 단위를 skill이라 부른다.

학습경로를 구성하려면 우선 KC의 선후관계가 정의되어야 한다. 학습경로에 관한 연구로 Chen et al.(2018)은 학생들이 사용하는 교과서와 같은 학습 교재들로부터 KC를 추출한 후, Apriori 알고리즘(Hegland, 2007)에 기반한 확률 수식을 통해 서로 다른 두 $KC(KC(i),\ KC(j))$의 선후관계를 유도하였다. Choi, Lee(2022a)는 Chen et al.(2018)이 사용했던 Apriori 알고리즘 대신, 라쏘(least absolute shrinkage and selection operator, LASSO) 파라미터를 활용할 수 있고 교차검증이 가능한 엘라스틱넷(Elastic Net) 알고리즘과 랜덤 포레스트(random forest, RF) 알고리즘을 이용하여 유의한 연관 관계들을 골라내었다. 이후, 답안에서 발견되지 않는 확률적 요인들과 시계열 개념을 고려한 HMM으로 앞서 추출한 연관 관계들의 선후관계를 확정하였다. 이는 D사에서 제공한 학습경로와 비교하여 Choi, Lee(2022b)가 먼저 발표했던 multi state Markov model(MSMM)을 이용한 모델보다 7%가량의 정확도 향상을 보였음을 확인하였다.

학생들은 KC들이 묶여 있는 “콘셉트”라 불리는 상위 개념(예: 분수, 곱셈)을 단위 수업 내에서 획득할 수도 있고, 여러 번의 수업에 걸쳐서 획득할 수도 있다. 즉, 단위 수업에서 획득하는 지식의 양은 더 이상 쪼개질 수 없는 개념인 KC에 의존하기보다는 더 큰 개념인 “콘셉트”를 얼마나 이해하냐에 달려있다. 그러므로, Choi, Lee(2022b)의 연구에서처럼 수집되는 데이터에 근거해 KC들의 선후관계를 정의하기보다는, KC들을 그룹화해 놓은 잠재 변인들의 선후관계를 찾아내는 작업이 좀 더 이해하기 쉬운 선후관계를 도출하게 해준다.

잠재 변인 간의 연관관계를 파악하는 것은 구조방정식 모형(structural equation model, SEM)을 통하여 가능하다. 그러나 Bullock, Harlow, Mulaik(1994)에서 언급한 것처럼 구조방정식 모형화를 이용하면 미리 설정된 선후관계에 따라 잠재 변수들의 연관관계와 그 타당성은 알 수 있지만, 사전에 잠재 변수들의 선후관계를 지정하는 것은 분석자의 몫이다. 본 연구에서는 개념 간의 선후관계를 결정하기 위하여 HMM을 사용한다. 이를 통하여 KC의 순서를 결정하고 집합이론에 따라 KC의 그룹으로 나타나는 잠재 변수인 “콘셉트”들의 순서를 결정하는 작업을 수행할 것이다. 결과적으로 상위 개념 즉, “콘셉트”들이 노드가 되는 학습경로를 완성하게 된다.

2. 구조방정식 모형과 hidden Markov model

2.1. 구조방정식 모형

관찰변수로 쓰이는 KC들의 그룹이면서 잠재 변수인 “콘셉트”와의 관계를 알기 위해 구조방정식 모형을 고려할 수 있다. 구조방정식 모형은 변수 간의 연관관계를 체계화한 것으로 상관분석, 인자분석, 회귀분석 등의 전통적 통계분석기법들을 포함하며 (Hwang, Kang, 2022; Lee, Kang, 2021), 관찰변수 간의 측정모형과 잠재 변수 간의 구조모형을 파악할 수 있게 한다. 그러나, 올바른 구조모형의 설정을 위해서는 Cohen et al.(1990)에 명시되었듯이 잠재 변수 간의 인과관계에 대한 가설이 필요하다.

구조방정식 모형을 수학적 견지에서 논의하고자 한다. 잠재 변수는 타당도와 신뢰도의 평가가 가능한 관찰변수들의 선형 결합으로 구성된다. 예를 들어, 관찰변수들이 X_1, X_2, X_3 로 구성되고, 이들에 대한 잠재 변수가 F라고 한다면 구조방정식 모형은 식 (1)과 같이 표현할 수 있다.

$$\begin{cases} X_1 = \lambda_1 F + \delta_{1,} \\ X_2 = \lambda_2 F + \delta_{2,} \\ X_3 = \lambda_3 F + \delta_3 \end{cases} \tag{1}$$

위 식에서 $\lambda_{1,}\lambda_{2,}\lambda_3$는 각 관찰변수와 잠재 변수의 관련성을 나타내며, 인자 적재량(factor loading) 또는 요인 부하량으로 불린다. 그리고, $\delta_{1,}\delta_{2,}\delta_3$는 관찰변수의 측정값 중 잠재 변수로 설명할 수 없는 부분을 나타낸다.

구조방정식 생성을 위한 접근방법으로 관측 데이터의 다변량 정규분포를 가정할 수 있는 covariance based equation modeling(CB SEM)과 CB SEM의 가정을 완화한 partial least squares SEM(PLS SEM)의 두 가지가 존재한다. Table 1은 이들의 성격을 가정, 빈도, 장단점의 측면에서 비교한다. (Hair et al. 2022; Dash, Ganesh, Paul 2021; Astrachan et al. 2014)

Table 1에서 확인할 수 있듯이 CB SEM은 다변량 정규분포 가정에 따라 이론적으로 설정한 모델이 관측치로부터 만들어진 공분산 행렬을 얼마나 가깝게 재생성할 수 있는가에 초점이 있지만, 정규분포의 가정이 완화된 PLS SEM은 모형이 반응변수의 분산을 얼마나 잘 설명할 수 있는지에 관심이 있다. 그러므로 CB SEM은 관측변수와 잠재 변수의 공통 요인(common factor)에 관심이 있게 되고 PLS SEM은 잠재 변수와 관측변수 사이의 최소제곱법(ordinary least square, OLS)를 통한 추정치를 구하는 접근을 수행한다(Hair Jr, 2021).

참고로, Finney, DiStefano(2006)는 관측치가 정규분포를 따르지 않는 경우의 구조방정식 모형추정을 위하여 점근적 분포 무관(asymptotically distribution free) 방법 또는 가중 최소제곱법(weighted least squares, WLS)을 활용하여 모수를 추정할 수 있음을 언급하였다. 또한, Lee, Kang(2021), Song, Kang(2021), Hwang, Kang(2022)은 최대우도(maximum likelihood, ML)법이 비정규 분포에서도 비교적 잘 작동하는 것을 보였다. 하지만 이들 모수 추정 방법은 변수 간의 관계에서 발생하는 행렬 연산 문제들이 해결되었을 때 활용할 수 있다.

Table 1. CB SEM vs. PLS SEM

	CB SEM	PLS SEM
assumption	distribution should follow normality common factor-based SEM latent variable is considered as common factor	no assumption needed composite-based SEM latent variable is considered as composite of measured variables
minimum # of data required	requires more than 200 (Kline, 2005)	must be greater than 10 times the measurement variable
strength	suited for theory testing and confirmation able to use fit indices using ML	suited for prediction and development requires not much data size able to perform complicated model
weakness	requires rigid distribution assumption requires big data size	not able to use ML based model evaluation.

2.2. hidden Markov model(HMM)

HMM은 관찰할 수 있는 값이 알지 못하는 상태 값의 확률적 영향을 받아 나타난다는 개념에 기반하여 만들어진 모형이다. 시계열 데이터가 존재할 때 각 시점에서 관찰되는 값들이 특정 은닉상태(s)의 영향을 받아 나타난다면, 각 상태(s)의 초기확률(π), 시간의 변화에 따른 상태 전이확률(A), 상태가 현실에서 어떤 값으로 나타날지에 대한 방출확률(B)이 존재하고 관찰값을 이용하여 이에 대한 계산이 가능할 것이다. HMM에서는 EM 알고리즘(Expectation maximization algorithm) 또는 HMM에 특화된 용어인 BW 알고리즘(Baum-welch algorithm)을 이용하여 이 값들을 계산한다(McLachlan, 2007). 이를 기반으로 HMM은 관찰값이 나올 수 있는 목적함수를 최대화하는 과정을 반복함으로써 파라미터들의 최종 추정치를 도출하는 모형이다(Zucchini, MacDonald, Langrock, 2016).

본 논문에서는 학생의 문제 풀이 로그 데이터를 이용하여 시간에 따라 관측되는 문제 풀이 결과를 사용하여 가능한 모든 KC쌍에 대한 전이확률을 계산하는 것에 초점을 둔다. 즉, 임의로 뽑은 두 개의 KC에 대하여 관찰된 값을 추출하고 HMM을 이용하여 추출된 데이터에 대한 전이확률(A)을 계산하는 방식이다. 이후, Chen et al. (2018)의 수식에 따라 앞에서 계산된 전이확률(A)을 이용하여 KC간의 선후관계를 결정한다. Chen et al. (2018)은 아래 식 (2), (3)에서 정의된 $KC(i)$, $KC(j)$의 전이확률이 미리 정한 유의수준인 α를 만족한다면 선후관계 $KC(i) \rightarrow KC(j)$가 성립한다고 기술하였다.

$$P(KC(i)=1|KC(j)=1) \geq \alpha \tag{2}$$

$$P(KC(j)=0|KC(i)=0) \geq \alpha \tag{3}$$

$$i \neq j$$

$KC(i)$와 $KC(j)$는 알면 1, 모르면 0의 값을 가진다. 다시 말해 j번째 KC를 알 때 i번째 KC를 알 확률이 α이상이고, i번째 KC를 모를 때 j번째 KC도 모르는 확률이 α 이상이라면 i번째 KC는 j번째 KC의 선수개념이다.

3. 연구자료 및 연구 방법

3.1. 연구자료

D사에서 제공한 개별 학생의 문제 풀이 로그를 활용하였다. 해당 문제 풀이 로그에는 학생의 학습 단위인 대분류(콘셉트), 중분류(KC), 소분류(problem)에 대한 정보와 문제 풀이 정확도가 기입되어 있다. 중분류의 이름을 KC라고 했지만, 여기에서 KC는 쪼개질 수 없는 세분된 개념의 단위가 아니라 단위 수업에서 얻는 개념 일부를 KC로 정의하였다. Table 2에는 문제 풀이 로그에 대한 요약통계와 함께 구조방정식 모형을 적용하기에 필요한 최소한의 표본 수가 기록되어 있다.

잠재 변수로 쓰일 “콘셉트”의 수는 레벨별로 3~6개이고, 관찰변수로 쓰일 KC의 수는 13~22개이다. 마지막 행에 기입한 최소 표본 수는 Kline(2015)의 절대적 기준, Nunnally(1967)의 관찰변수 기준, 관찰변수와 잠재 변수의 수의 비에서 얻은 최소 표본 수의 최댓값이다. Table 2에 따라 3행의 관측치 수와 비교하여 D사의 로그는 실험에 충분한 수의 데이터 수를 확보하고 있음을 알 수 있다. Table 3은 13~15레벨의 데이터 중 13레벨의 각 KC별 관측치를 나타낸다.

Table 2. Number of concepts, *KC*s and records

level	13	14	15
Number of concept	6	4	3
number of *KC*	22	16	13
number of records	2,539	1,736	1,404
Required number of samples	220	200	200

Table 3. Students' problem solving log of level 13 (row 1~ row 4)

no	KC 01	KC 02	KC 03	KC 04	KC 05	KC 06	KC 07	KC 09	KC 10	KC 11	KC 12
1	1	0.6	0.6	0.6	0.7	0	1	1	1	0	0.75
2	1	1	1	1	1	1	1	0.8	1	1	1
3	1	0.5	0.5	0.5	1	0.3	0.5	0.5	0.8	0	0.5
4	1	1	1	1	1	1	1	1	1	1	1

no	KC 13	KC 14	KC 15	KC 16	KC 17	KC 18	KC 19	KC 20	KC 21	KC 22	KC 24
1	1	0.8	0.6	0.6	1	1	1	0	1	1	0.8
2	1	1	1	1	1	1	1	1	1	1	1
3	0	0.5	0	0.1	0.8	0.5	0.5	0.5	0.5	0	0.4
4	1	1	1	0.6	0.7	0.5	1	0	1	1	0.6

3.2. 연구 방법

본 논문의 연구 절차를 Figure 1에 나타내었다. 정규성 여부 등 연구자료의 특징을 파악한 후 관찰변수와 잠재 변수의 구조방정식 모형을 설정한다. 분석에 사용할 데이터가 정규성을 보이지 않으므로 R의 LAVAAN(Rosseel, 2012)이 아닌, R의 SEMPLS(Hair Jr et al., 2021), R의 PLSPM(Ravand, Baghaei, 2016), SmartPLS(Ringle, Silva, Bido, 2015)를 이용하여 관찰변수와 잠재 변수의 관계 강도를 확인한다. 관찰변수들의 선후관계는 HMM을 이용하여 확인되며, 관찰변수들의 집합으로 이루어진 잠재 변수들의 선후관계는 집합이론에 따라 관찰변수의 방향성에 근거하여 결정된다. 각 단계의 상세한 내용을 1)~4)에서 설명하겠다.

1) 데이터 클렌징

D사의 수학학습 레벨 평가 데이터(13~15레벨)에 대하여 이상치 들을 제거하는 작업과 변수별 분포 형태를 파악하는 작업을 수행한다.

2) 구조방정식 모형 설정

D사에서 정의한 지식 콘텐츠의 단위인 각 *KC*들을 관찰변수들로 할당한다. 이후 각 *KC* 그룹의 콘셉트를 잠재 변수로 설정한 후 구조방정식 모형화를 수행한다.

3) HMM을 통한 잠재 변수들의 인과관계 파악

Choi, Lee(2022b)에서 보였듯이, HMM 알고리즘을 이용하여 *KC*간의 전이확률을 계산함으로써

“콘셉트”간의 선후관계를 파악할 수 있다. 본 논문에서 사용하는 문제 풀이 데이터의 경우 각 상태(예: 모름, 습득)의 확률적 성질, 즉 ‘개념을 습득했으면서도 실수해서 틀림’, ‘모르면서도 추측해서 맞음’ 등의 오류를 고려한다면, 전이확률의 계산을 위하여 HMM을 활용하여야 한다. 식 (2), (3)에 따라 두 개의 *KC*에 선후관계가 존재하는 것으로 나타난다고 하자. 이럴 때 Hacking(2001)의 귀납 논증을 이용하여 관찰변수들의 선후관계에 근거하여 잠재 변수들의 선후관계를 얻을 수 있다. 참고로 HMM의 선후관계는 Choi, Lee(2022b)에서 논의되었듯이, LASSO, RF 등의 방법을 통해 유의한 연관관계로 판명된 경우를 조건으로 하여 얻도록 한다.

4) Diagram **생성 및 관측오류 파악**

학습경로 다이어그램은 SmartPLS 상용소프트웨어를 이용해 생성하고, R의 PLSPM, R의 LAVAAN, R의 SEMPLS 패키지를 이용하여 “콘셉트”간의 연결 강도 및 관찰변수의 신뢰성과 타당성을 검증한다. 참고로 원시 데이터의 정규성을 가정하는 R의 LAVAAN은 행렬 연산 시의 오류로 비교 대상에서 제외하였다. 마지막으로, 신뢰성과 타당성이 보장되는 경우 잠재 변인 간의 관계 및 잠재 변인과 관찰 변인의 관계에 대한 분석을 수행한다.

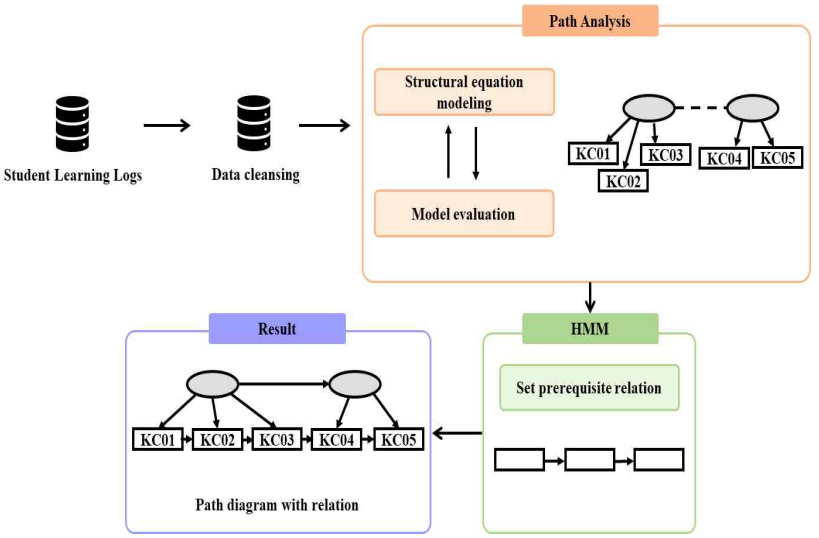

Figure 1. Analytical procedure

4. **실험 결과**

4.1. **정규분포를 위한 *KC* 데이터 변환 시도**

관찰변수인 *KC* 각각에 대한 정확도 분포는 Figure 2와 같이 왼쪽으로 꼬리가 긴 형태(Left Skewed)로 나타났다. 레벨별로 존재하는 모든 *KC*에 대한 SQRT, LOG, EXP, INVERSE 변환을 시도하였으나, 정규성을 보이는 분포를 찾을 수 없었다.

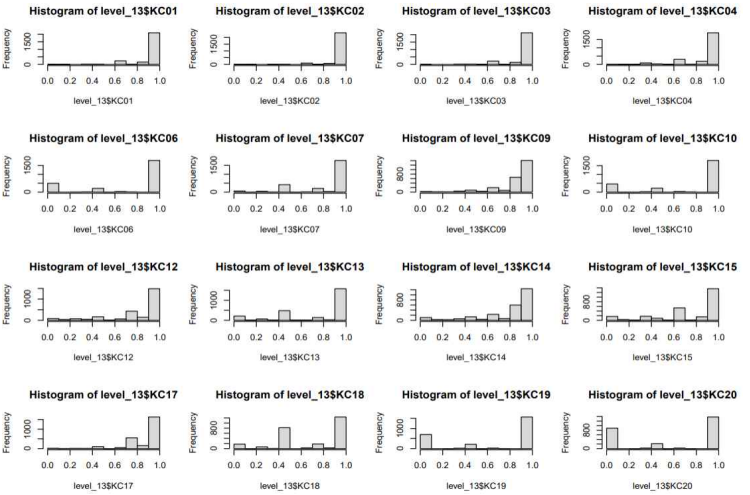

Figure 2. KC histogram of level 13

4.2. 데이터 클렌징

Garbage In Garbage Out (Bininda-Emonds et al., 2004)에 따라 편향 없이 명확하고 깨끗한 데이터를 확보하는 작업은 의사결정에 매우 중요한 역할을 한다. 데이터 클렌징 규칙은 다음과 같다.

(1) 모든 KC에서 정답이었던 학생 레코드는 삭제한다.

(2) 모든 KC에서 오답이었던 학생 레코드는 삭제한다.

(3) 모든 학생이 정답을 보인 KC는 삭제한다.

(4) 모든 학생이 오답을 보인 KC는 삭제한다.

데이터 클렌징을 수행한 후 Hwang, Kang(2022)에서 논의된 바에 따라 WLS 또는 부트스트래핑(Bootstrapping) 알고리즘을 활용한 ML을 이용하여 영향도 계수를 계산하는 것을 고려하였다. 그러나, 데이터 내에 존재하는 변수 간의 선형 결합으로 양의 정부호 행렬(positive definite matrix) 관련 오류를 피할 수 없었다. 결국, PLSSEM을 사용하여 잠재 변수와 관찰변수의 관계를 확인하였다.

4.3. 계층적 hidden Markov model 수행

각 KC의 상태 '모름', '습득'에 따른 전이확률을 HMM을 활용하여 예측한 후, Chen et al. (2018)의 수식에 따라 KC 간의 선후관계를 얻었다. $KC(i)$와 $KC(j)$가 대상이고. i와 j가 시간 순서를 가지고 나타난다고 하자. 이들에 대한 관측값이 0/1이라면 Table 2의 데이터를 이용하여 모름->모름, 모름->습득, 습득->모름, 습득->습득의 전이확률을 계산할 수 있다. 표의 값들이 실수형 값을 가지므로 R의 HMM 함수를 이용하기 위하여 이분화된 값으로 치환하는 과정을 수행하였다. 이를 바탕으로 3.2의 4)에서 논의된 귀납 논증에 따라 "콘셉트" 간의 선후관계를 얻을 수 있다.

4.4. KC와 KC들의 그룹인 콘셉트와의 관계에 대한 신뢰도

잠재 변인에 대한 신뢰도를 R의 PLSPM에서 보여주는 4가지 통계량 모두를 이용하여 판단하였다. 특히 PLSPM의 통계량 중 크론바흐 알파(Chronbach's alpha)는 정규분포가 가정되고 치우친(skewed) 분포가 아니면서 대표본일 때 사용할 수 있다(Trizano-Hermosilla, Alvarado, 2016).

PLSPM에서 보여주는 Table 4의 Chronbach's alpha, Dilon-Goldstein's rho 식(4), first and second eigenvalues of correlation matrix로부터 종합적으로 판단할 때, Cronbach's alpha에 따르면 concept 1, concept 3, concept 5가 신뢰도의 하한인 0.7 미만으로 하한값을 맞히지 못하는 것으로 나타나지만, rho ($\geq$ 0.7)를 포함하여 전반적인 값으로부터 판단하면 "콘셉트"들과 이들을 구성하는 *KC*들이 같은 방향의 정보를 보이는지(신뢰성)에는 문제가 없는 것으로 보인다.

$$\frac{\left(\sum_{i=1}^{k} std.\lambda_i\right)^2}{\left(\sum_{i=1}^{k} std.\lambda_i\right)^2 + \sum_{i=1}^{k}(1 - std.\lambda_i^2)} \tag{4}$$

식 (4)는 Dilon-Goldstein's rho에 대한 식으로 i는 측정 변인의 요인적재량에 대한 임의의 순서변수, k는 한 concept에 할당된 KC의 수, λ는 요인적재량을 의미한다.

Table 4. Reliability of each concepts

	C.alpha $\geq$ 0.7	DG.rho $\geq$ 0.7	eig.1st $\gg$ 1	eig.2nd
concept1	0.4004	0.7694	1.2503	0.7497
concept2	0.7805	0.8752	2.1092	0.7641
concept3	0.6224	0.7795	1.8827	0.7855
concept4	0.8530	0.9045	2.8347	0.7270
concept5	0.5027	0.7510	1.5074	0.8184
concept6	0.7643	0.8413	2.8960	1.1020

4.5. 타당도

타당도에는 관측 변인과 잠재 변인과의 관련성을 측정하는 집중 타당도와 관측 변인이 자신이 포함된 잠재 변인과 관련성이 가장 큰지를 측정하는 판별타당도가 있다. Bootstrapping 결과 도출된 모든 잠재 변인과 관측 변인의 모든 쌍은 집중 타당도를 만족하는 것으로 결론하였으나, Table 5에서 확인하듯 concept 3, concept 5, concept 6의 평균 분산 추출(average variance extracted, AVE) 값이 판별타당도(Lee, Kweon, 2021)를 만족하는 값 0.5를 기준으로 근소한 차이로 비교적 낮은 값을 가지는 것을 알 수 있다.

$$\frac{\sum_{i=1}^{k}(std.\lambda_i^2)}{\sum_{i=1}^{k}(std.\lambda_i^2) + \sum_{i=1}^{k}(1 - std.\lambda_i^2)} \tag{5}$$

식(5)는 AVE에 대한 식으로 i는 측 정변인 요인적재량에 대한 임의의 순서변수, k는 한 concept에 할당된 KC의 수, λ는 요인적재량을 의미한다.

Table 5. AVE of each concept

concept	1	2	3	4	5	6
AVE	0.6250	0.7002	0.4603	0.7069	0.4998	0.4823

4.6. 선후관계의 반영

HMM에서 얻은 *KC*간의 선후관계를 귀납 논증에 따라 잠재 변인의 선후관계로 확장하여 SmartPLS로 PLSSEM을 수행한 결과는 Figure 3과 같다. 잠재 변인(파란색 원)에서 뻗어나가는 화살표에 적힌 숫자는 요인적재량(괄호 안은 t값)을 나타내고 잠재 변인끼리 연결되는 화살표의 숫자는 경로계수를 나타낸다. 요인적재량, 경로계수, t값은 부트스트래핑을 통해서 얻은 값으로 원시 데이터는 정규분포를 따르지 않았지만, 정규분포 화한 것으로 가정하고 얻은 값이다.

이에 따르면 concept 2(서로 다른 자릿수인 소수의 덧셈과 뺄셈)와 concept 3(소수의 자연수 곱셈)가 약한 연결 관계인 것으로 보인다. 즉, concept 3를 공부하기 위해 concept 2를 공부하는 것은 꼭 필요하지 않은 것으로 결론할 수 있다.

또한, 신뢰성과 타당성 검사를 통과한 계수들을 살펴보면, 가끔 약한 관계를 보이는 값들이 눈에 띄지만 대부분 잠재 변인을 측정하기 위한 타당성 있는 관찰변수인 것으로 판단된다.

Table 6은 실험에 쓰인 D사의 수학학습데이터 13레벨의 “콘셉트”와 *KC*의 이름을 나열한다.

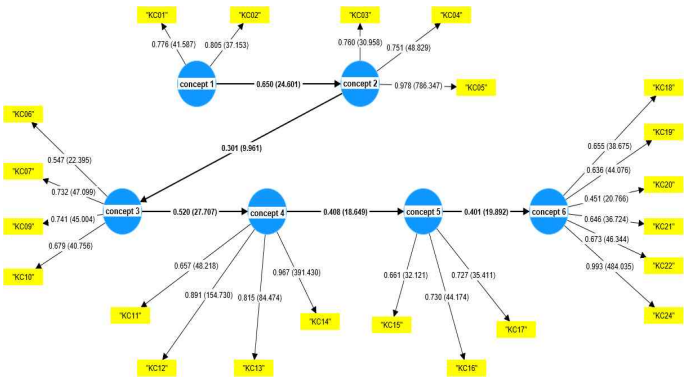

Figure 3. Learning path of concepts and *KC*s

Table 6. Titles for concepts and *KC*s in level

concept	KC	title
01		**Addition and subtraction of decimals with the same number of digits**
	01	Addition of decimals with the same number of digits
	02	Subtraction of decimals with the same number of digits
02		**Addition and subtraction of decimals with different number of digits**
	03	Addition of decimals with different number of digits
	04	Subtraction of decimals with different number of digits
	05	Addition and subtraction of various decimals
03		**Multiplication of decimal and natural number**
	06	the decimal place of (decimal)x(10/100/1000/10000)
	07	the decimal place of (decimal)x(a few/dozens/hundreds)
	09	(decimal)x(natural number)
	10	(natural number)x(decimal)
04		**Multiplication of decimals**
	11	the decimal place of multiplication of decimals
	12	(single digit decimal)x(decimal)
	13	(two digit decimal)x(decimal) / (three digit decimal)x(decimal)
	14	multiplication of various decimals

Table 6. Titles for concepts and *KC*s in level (continued)

05		**Division of decimal and natural number**
	15	the decimal place of (natural number/decimal)÷(10/100/1000/10000)
	16	(decimal)÷(natural number) / (natural number)÷(decimal) using division of natural numbers
	17	(decimal)÷(natural number) / (natural number)÷(natural number)
06		**Division of decimals**
	18	(single digit decimal)÷(single digit decimal)
	19	(two digit decimal)÷(two digit decimal)
	20	(two digit decimal)÷(single digit decimal)
	21	(natural number)÷(single digit decimal)
	22	(natural number)÷(two digit decimal)
	24	division of various decimals

4.7. 적재량 비교(SEMPLS, PLSPM, SmartPLS)

SEMPLS(R), PLSPM(R), SmartPLS에서 보여주는 적재량을 비교한 결과는 Table 7, Table 8과 같다. 적재 값들이 대부분 0.6 이상으로 세부 개념들이 그룹 개념의 정의에 벗어나지 않는 출제경향을 보이고 있음을 알 수 있다.

Table 7. Comparison of path coefficients

from	concept 1	concept 2	concept 3	concept 4	concept 5
to	concept 2	concept 3	concept 4	concept 5	concept 6
SEMPLS	0.65	0.32	0.53	0.42	0.42
PLSPM	0.64	0.30	0.51	0.40	0.40
SmartPLS	0.65	0.30	0.52	0.40	0.40

Table 8. Factor loadings for the three different tools

	concept 1		concept 2			concept 3				concept 4			
	KC 01	KC 02	KC 03	KC 04	KC 05	KC 06	KC 07	KC 09	KC 10	KC 11	KC 12	KC 13	KC 14
SEMPLS	0.78	0.81	0.77	0.76	0.98	0.56	0.74	0.75	0.67	0.66	0.89	0.82	0.97
PLSPM	0.77	0.80	0.76	0.75	0.97	0.54	0.73	0.75	0.66	0.65	0.89	0.81	0.96
SmartPLS	0.76	0.80	0.76	0.75	0.97	0.54	0.73	0.74	0.67	0.65	0.89	0.81	0.96

	concept 5					concept 6			
	KC 15	KC 16	KC 17	KC 18	KC 19	KC 20	KC 21	KC 22	KC 24
SEMPLS	0.67	0.74	0.73	0.66	0.64	0.47	0.65	0.67	0.99
PLSPM	0.66	0.73	0.72	0.65	0.63	0.45	0.64	0.67	0.99
SmartPLS	0.66	0.73	0.72	0.65	0.63	0.45	0.64	0.67	0.99

5. 결론 및 제언

본 연구에서는 수학 학습데이터의 *KC*별 관찰치를 이용하여 잠재 변인 간의 선후관계를 알아내었다. 잠재 변인 간의 연관관계를 분석함으로써 개념 간의 상호작용을 알아낼 수는 있겠지만, 이에

더하여 구조방정식, HMM, 귀납 논증의 개념을 이용하여 잠재 변인 간의 선후관계를 고려한 학습경로를 생성하였다. 이를 통해, 그 결과 적응형 학습에 맞는 개념의 습득을 위하여 반드시 선행되어야 하는 포괄적인 개념의 순서가 결정될 수 있음을 보였다.

예를 들어, “나눗셈” -> “분수” -> “분수의 나눗셈”과 같이 생성된 경로를 통해, 분수의 나눗셈을 잘하기 위해서는 나눗셈과 분수에 대한 포괄적인 개념이 필요하다는 사실을 데이터로부터 얻을 수 있게 되는 것이다. 특히, Table 6에서는 구조방정식과 HMM의 혼합 모형에 따라, 소수의 덧셈을 하려면 자릿수가 같은 소수의 덧셈을 먼저 학습한 후 자릿수가 다른 소수의 덧셈을 학습해야 한다는 것을 보인다. 이를 통하여 데이터를 활용한 적응형 학습이 가능하게 되는 것이다.

본 연구에서는 D사에서 제공한 수학학습데이터를 이용하여 학습경로를 생성하는 작업을 수행하였다. 그러나, 방법론의 적절성을 증명하기 위하여 공개 데이터를 활용하고 모형에서 알아낸 선후관계가 경험적으로 알고 있는 다른 방법론들과 비교하여 최적인가의 여부를 확인하는 작업이 추가로 필요할 것으로 예상된다.

References

Astrachan, C. B., Patel, V. K., & Wanzenried, G. (2014). A comparative study of CB-SEM and PLS-SEM for theory development in family firm research. *Journal of Family Business Strategy*, 5(1), 116-128. DOI: https://doi.org/10.1016/j.jfbs.2013.12.002

Bininda-Emonds, O. R., Jones, K. E., Price, S. A., Cardillo, M., Grenyer, R., Purvis, A. (2004). Garbage in, garbage out, *Phylogenetic Supertrees*, 4, 267-280. DOI: https://doi.org/10.1007/978-1-4020-2330-9_13

Bullock, H. E., Harlow, L. L., Mulaik, S. A. (1994). Causation issues in structural equation modeling research, Structural Equation Modeling, *A Multidisciplinary Journal*, 1(3), 253-267. DOI: https://doi.org/10.1080/10705519409539977

Cha, H. (2022). Analysis of Changes in Daily Life and Behavior due to COVID-19, *Journal of the Korean Data Analysis Society* (August 2022), 24(4), 1483-1497. (in Korean). DOI: 10.37727/jkdas.2022.24.4.1483

Choi, H. H., Lee, M. J. (2022a). Analysis of prerequisite relation in knowledge graph using ARM and MSMM: Focusing on problem evaluation data of K-12 math. *Journal of Digital Contents Society*, 23(6), 1131-1140. (in Korean). DOI: http://dx.doi.org/10.9728/dcs.2022.23.6.1131

Choi, H. H., Lee, M. J. (2022b). Analysis of prerequisite relation in knowledge graph using ElasticNet (LASSO)+ RF+ HMM: Focusing on K-12 math, *Digital Contents Society*, 23(10), 1981-1990. (in Korean). DOI: http://dx.doi.org/10.9728/dcs.2022.23.10.1981

Cohen, P., Cohen, J., Teresi, J., Marchi, M., & Velez, C. N. (1990). Problems in the measurement of latent variables in structural equations causal models, *Applied Psychological Measurement*,14(2), 183-196. DOI: https://doi.org/10.1177/014662169001400207

Chen, P., Lu, Y., Zheng, V. W., Chen, X., Yang, B. (2018). Knowedu: A system to construct knowledge graph for education. *IEEE Access*, 6, 31553-31563. DOI: 10.1109/ACCESS.2018.2839607

Dash, G., Paul, J. (2021). CB-SEM vs PLS-SEM methods for research in social sciences and technology forecasting. *Technological Forecasting and Social Change*, 173, 121092. DOI: https://doi.org/10.1016/j.techfore.2021.121092

Finney, S. J., DiStefano, C. (2006). Non-normal and categorical data in structural equation modeling. *Structural equation modeling*: A second course, 10(6), 269-314.

F. Li, Y. He, Q. Xue (2021). Progress, challenges and countermeasures of adaptive learning. *Educational Technology & Society*, 24(3), 238-255.

Hacking, I. (2001). An introduction to probability and inductive logic. Cambridge university press. DOI: https://doi.org/10.1017%2Fs1079898600004297

Hair Jr, J. F., Matthews, L. M., Matthews, R. L., & Sarstedt, M. (2017). PLS-SEM or CB-SEM: updated guidelines on which method to use. *International Journal of Multivariate Data Analysis*, 1(2), 107-123. DOI: https://doi.org/10.1504/IJMDA.2017.087624

Hair Jr, J. F., Hult, G. T. M., Ringle, C. M., Sarstedt, M., Danks, N. P., & Ray, S. (2021). Partial least squares structural equation modeling (PLS-SEM) using R: A workbook. DOI: https://doi.org/10.1007/978-3-030-80519-7

Hegland, M. (2007). The apriori algorithm – a tutorial. *Mathematics and computation in imaging science and information processing*, 209-262.

Hwang, I., Kang, H. (2022). Comparative Study on Testing Methods of Path Coefficient in Structural Equation Model, *Journal of the Korean Data Analysis Society*, 24(3), 1007-1016. (in Korean). DOI : 10.37727/jkdas.2022.24.3.1007

Kline, Rex B. (2015). Principles and practice of structural equation modeling. Guilford publications.

Lee, K. T., Kang, H. (2021). Evaluation of type I error of fit indices for structural equation model under normal and exponential distribution, *Journal of the Korean Data Analysis Society*, 23(1), 173-181. (in Korean). DOI : 10.37727/jkdas.2021.23.2.599

Lee, S., Kweon, Y.(2021). Validity and Reliability of Measurement Scale on Recognition about Sex Education for Students with Disability. *Journal of the Korean Data Analysis Society*, 23(2), 757-769. (in Korean). DOI: 10.37727/jkdas.2021.23.2.757

McLachlan, G. J., & Krishnan, T. (2007). The EM algorithm and extensions, second edition. DOI:10.1002/9780470191613

Nunnally, Jum C (1967), Psychometric theory

Ravand, H., Baghaei, P. (2016). Partial least squares structural equation modeling with R. *Practical Assessment, Research, and Evaluation*, 21(1), 11. DOI: https://doi.org/10.7275/d2fa-qv48

Bido, D., da Silva, D., & Ringle, C.(2014). Structural Equation Modeling with the Smartpls. *Brazilian Journal Of Marketing*, 13(2), 18.

Rosseel, Y. (2012). lavaan: An R package for structural equation modeling. *Journal of statistical software*, 48, 1-36. DOI: 10.18637/jss.v048.i02

Song, Y. S., Kang, H. (2021). Evaluation of type Ⅱ error of fit indices for structural equation model under normal and exponential distribution, J*ournal of the Korean Data Analysis Society*, 23(2), 599-609. (in Korean). DOI : 10.37727/jkdas.2021.23.2.599

Trizano-Hermosilla, I., & Alvarado, J. M. (2016). Best alternatives to Cronbach's alpha reliability in realistic conditions: congeneric and asymmetrical measurements, *Frontiers in psychology*, 7, 769. DOI: https://doi.org/10.3389/fpsyg.2016.00769

Zucchini, W., MacDonald, I. L., Langrock, R. (2016), Hidden Markov Models for Time Series: An Introduction Using R, Second Edition. Chapman & Hall/CRC

Sequential relationship analysis of potential learning concepts : using structural equation modeling and HMM

Choi, Hyunhee[1], *Lee Yunji*[2]

Abstract

As people use non-face-to-face learning frequently, interest in adaptive learning for efficient learning is increasing. In order for students to easily learn, it is necessary to set up a learning path that considers students' learning outcomes. However, as everyone recognizes, learning pathways are not created based on learning logs, but rather rely on the curriculum that experienced teachers have used. However, the answer to the question "Can today's students learn efficiently with the existing curriculum system?" is perhaps not certain. In addition to studies whose subjects were creating a learning path, this study uses a structural equation model, Hidden Markov Model (HMM) and inductive reasoning to create a hierarchical learning path between latent factors at a higher level. Using the mathematics learning data of company D in Korea, a learning path of concepts rather than a learning path of subdivided concepts was created. It was confirmed that the subdivided concepts showed reliable observation values for the upper concepts and that the subdivided concepts conveyed the contents whose concepts were conveyed with validity.

Keywords : learning path, Sequential Equation Modeling(SEM), Hidden Markov Model(HMM), inductive reasoning.

[1](Corresponding author) Senior Researcher, LAIVDATA, 29-30 Seocho-daero 54-gil, Seocho-gu, Seoul, 06633, Korea. E-mail: choihh@laivdata.com

[2]undergraduate student, Department of Applied Statistics, Chung-Ang University, 84, Heukseok-ro, Dongjak-gu, Seoul, 06974, Republic of Korea. E-mail: pioneeryjlee@laivdata.com

[Received 30 November 2022; Revised 20 December 2022; Accepted 31 December 2022]