Journal of the Korean Data Analysis Society (April 2023), 25(2), 585-597.
https://doi.org/10.37727/jkdas.2023.25.2.585

# 은닉 마르코프 모델을 이용한 적응형 학습경로 생성에 관한 연구

최현희[1], 이윤지[2], 이하윤[3]

## 요 약

전 세계적인 COVID19의 영향으로, 비대면 학습에 대한 활용도가 높아지고 있다. 비대면 학습을 위해서는 효율성을 토대로 한 학습경로의 생성이 중요하다. 본 연구는 학생들이 수업에서 마주칠 수 있는 경험의 경로, 즉, 지식 개념(knowledge concept, *KC*) 을 순서대로 배열한 연결망으로 알려진 학습경로를 만드는 방법으로 hidden Markov model(HMM)을 소개하고, HMM을 이용하여 경로 예측의 정확도 향상을 목적으로 한다. 첫 단계로, 정확한 학습경로의 생성을 위하여 HMM 수행 전 least absolute shrinkage and selection operator(LASSO), random forest(RF)를 이용한 변수 선택(variable selection)을 수행한 후 변수 선택의 효과를 파악한다. 그리고 HMM을 이용해서 *KC*들의 그룹으로 만든 상위 개념들의 선후관계를 파악한 경우와 다른 후보 경로들과의 비교를 통하여 HMM을 활용하여 완성된 경로가 더욱 의미 있게 생성되었음을 입증한다. 실험을 위하여 AI-hub(https://aihub.or.kr/)에서 공유한 수학 학습데이터를 이용한 결과 LASSO, RF 등의 변수 선택 방법을 이용하여 관계 쌍을 추려냈을 때 HMM의 성능이 월등히 좋아졌고, 상위 개념으로 이루어진 학습경로를 평가할 때 HMM을 활용한 경우가 다른 모형에 비해 모형적합도 면에서 훌륭하였다.

*주요용어* : 은닉 마르코프 모델(HMM), 학습경로, 변수 선택(variable selection), 지식 개념(*KC*).

## 1. 서론

기술의 급속한 변화와 사회적 환경의 변화는 온라인 개학을 비롯한 비대면 학습을 가능하게 하였다(Park, Kim, 2020). 효율적인 비대면 학습이 되기 위해서는 교육 콘텐츠들의 묶음인 잘 짜인 학습순서의 구성이 필수적이다. 이러한 학습순서, 즉 학습경로를 Brusilovsky(1992)는 학생들이 수업에서 마주칠 수 있는 경험을 순서대로 배열한 연결망이라 정의하였다. Yang et al.(2010)은 지식 요소로 구성된 학습활동을 적절한 순서로 구성하여 학생들이 교과 영역을 효과적으로 학습할 수 있도록 하는 것을 학습경로의 구성으로 정의하였다. Muhammad et al.(2016)은 학습 목표를 달성하기 위해 사용자를 안내하면서 전제 조건을 충족하는 언급된 콘텐츠(learning object, LO), 주제 등의 순서를 학습경로라고 하였고, 연구자의 추측으로 학습경로를 만들고 경험적으로 보완할 수 있다고 언급하였다.

[1](교신저자) 06633 서초대로54길 29-30, 라이브데이터(주), 수석연구원. Email: choihh@laivdata.com
[2]06974 흑석로 84, 중앙대학교 응용통계학과 학부재학생. E-mail: pioneeryjlee@laivdata.com
[3]06974 흑석로 84, 중앙대학교 소프트웨어학부 학부재학생. E-mail: hayun0406@laivdata.com
[접수 2023년 1월 10일; 수정 2023년 2월 3일; 게재 확정 2023년 2월 9일]

최근 MOOC 등에서 활용하는 이러닝 학습 도구는 모든 학습 과정을 기록할 수 있도록 제공한다(Yoon, Choi, Kim, 2022). Chen(2008)은 학습자의 테스트 결과로부터 잘못된 응답 패턴을 추출하고, 최적에 가까운 학습경로를 구성하는 유전자 기반 개인화 이러닝 시스템을 제안하였다. 부정확한 답을 한 테스트 항목 중 난이도가 가장 작은 LO를 학습경로의 시작으로 지정하고 유전자 알고리즘을 활용해 개별 학습자에게 최적에 가까운 학습경로를 생성하는 방법을 소개하였다. Cai, Zhang, Dai(2019)는 학습 목표에 도달할 수 있도록 학습 로그를 이용하여 학습자의 학습 상황을 모형화하고, 임의 선택함수를 사용하여 학습경로를 생성하였다. Siren, Tzerpos(2022)는 기계 학습 분류기 알고리즘으로 LO를 추출한 후 개념지도 데이터를 이용해 학습경로를 생성하였다.

위의 3가지 사례로부터 확인된 학습경로 관련한 연구의 방향은 주어진 커리큘럼에 그대로 의존하기보다는 확률 개념을 도입하여 입력 데이터에 기반한 모형화를 시도하였다는 점이다. 참고로, Mandalapu, Gong, Chen(2021)은 변수 선택에 있어 기존의 변수 선택 방법과 심층 모델을 이용한 변수 선택 결과를 비교할 때, 기존의 변수 선택 방법을 활용하는 것이 더 훌륭한 결과를 가져옴을 언급하였다.

본 연구는 학생들이 시험에서 보여주는 정·오 데이터를 사용한다. 이 정·오 데이터는 문제 풀이 순서에 따라 시계열로 측정되는 데이터로서 특정 $KC$의 습득 여부가 다른 $KC$의 습득에 영향을 미칠 수 있다는 것을 염두에 둔다. 그러므로, 관련하고 있는 $KC$들의 순서를 효과적으로 조정하는 방법론을 설계하는 것이 연구의 핵심이 된다. 그런데, 학습경로를 설계할 때 “더 이상 쪼개질 수 없는 지식의 단위”인 $KC$의 정의에 따라 경로를 설계하는 경우 이해 불가능한 추천이 이루어질 수 있다. 그러므로 $KC$의 상위 개념에 따라 학습경로를 설계하고 이의 적합도를 평가하는 방법을 제언한다.

본 논문에서는 HMM을 소개한 후, 초등학교 저학년 “덧셈과 뺄셈” 수학 문제 풀이 데이터에 HMM을 적용하였다. 변수 선택기법을 이용하여 $KC$의 후보를 먼저 골라낸 후 HMM을 적용하였을 때, HMM만을 적용한 경우보다 약 40% 정확도가 향상된 것을 확인하였다. HMM의 직접적인 입력이 되었던 $KC$들의 선후관계를 중심으로 학습경로를 구성하지 않고 Choi, Lee(2023)에서 논의된 바와 같이 $KC$들을 상위 개념인 “콘셉트”라는 이름으로 군집한 후 “콘셉트” 중심의 학습경로를 구성한다고 하자. HMM에 기반하여 “콘셉트” 중심으로 생성한 경로와 HMM과는 관계가 없었던 경로와의 비교 후에 HMM에 기반하여 생성한 경로의 적합도가 goodness of fit(GOF) 측면에서 약 6% 높은 것으로 확인되었다.

## 2. HMM

HMM은 은닉된 상태(hidden state)와 관측상태(observable state)가 동시에 존재하는 시계열 데이터에 적용하는 모형으로, 모수인 초기확률(initial probability), 전이확률(transition probability), 방출확률(emission probability)을 예측하거나, 관측값으로부터 은닉상태의 값을 예측하는 것, 또는 모수 확률값들이 주어졌을 때 관측 시계열의 확률을 구하는 3가지 문제에 적용된다(Rabinar, 1989).

HMM의 이해를 도우려고 문제 풀이 예를 설명하고자 한다. $t$=1에서의 학습이 시작되기 전 이해 확률(모름(unlearned)/습득(learned))을 초기확률이라고 하고, 시간이 가면서 생성되는 모름→모름, 모름→습득, 습득→모름, 습득→습득과 같은 은닉상태의 변경 확률을 전이확률이라고 한다. 이해

정도에 따라 시험에서 정답/오답의 답(observable state)이 달리 나타날 수 있는데, 각 답이 관찰될 수 있는 확률을 방출확률이라고 한다. Kim, Lee(2019)는 은닉상태를 $U$, 반응변수를 $Y$, $i$번째 학습자의 성적을 $T$회에 걸쳐 관측한다면 은닉상태 $U_i=(U_{i1},..,U_{it},..,U_{iT})'$, 관찰치 $Y_i=(Y_{i1},..,Y_{it},..,Y_{iT})'$가 되며, 초기확률 $\pi_u^{(1)}=p(U_{i1}=u)$, 전이확률 $A=p(U_{it}=v|\ U_{it-1}=u)$, 방출확률 $B=p(Y_{it}=y|U_{it}=u)=\phi_{y|u}^{(t)}$로 정의하였다.

$\Theta=(\pi,A,B)$의 예측값은 EM 알고리즘(Expectation Maximization algorithm)을 수행하여 얻는다. Expectation 단계에서는 입력된 $\Theta$값을 기준으로 은닉상태에 대한 분포를 얻고, maximization 단계에서는 E 단계에서 얻은 은닉상태 분포를 최대화하는 갱신된 $\Theta$값을 얻는다. 즉. $\Theta$의 정의와 더불어 EM의 과정을 포함한 모형을 HMM이라 한다(Zucchini, MacDonald, Langrock, 2016).

EM 알고리즘을 시행하면서 국부 최적값(local optimum)에 빠지지 않고 $\Theta=(\pi,A,B)$를 구하려면 초깃값이 필요하다. 초깃값을 결정하는 방법에는 데이터의 특성을 반영하는 것, 임의의 값으로 설정하는 것, 추측에 의한 것으로 3가지가 있다.

### 1) 데이터의 특성 반영

Liu, Lemeire, Yang(2014)는 표면적으로 드러나는 특성과 k-평균 군집화(k-means clustering)로 찾아지는 숨겨져 있는 특성들을 고려하여 상태의 수를 대략 결정할 것을 제안하였다. 이후, $\Theta=(\pi,A,B)$의 초깃값을 식(1)~(3)과 같이 설정할 것을 제안하였다.

$$\pi_u = t=1\text{에서 상태 } u\text{의 빈도} \tag{1}$$

$$a_{uv}=\frac{\text{상태}u\text{에서 상태}v\text{로 이동하는 횟수}}{\text{상태}ui\text{에서 이동하는 횟수}} \tag{2}$$

$$b_v(k)=\frac{\text{상태}v\text{에서 } v_k\text{를 관찰하는 수}}{\text{상태}v\text{의 수}} \tag{3}$$

$$u,v:1,\cdots,\text{상태의 수},\quad k:1,\cdots,\text{관찰값 종류의 수}$$

학습에서 두 개의 상태 '모름'과 '습득'을 고려하고, 각 상태에 대해 관찰될 수 있는 값은 0 또는 1이다. 알고 모르고는 관찰할 수 있는 개념이 아니므로 측정한 $b_v(k)$는 관찰할 수 없다는 사실을 고려하여야 한다.

### 2) 임의의 값

Rabiner(1989)는 $\pi,A$는 모든 상태에 대해서 균일하거나 임의의 값을 할당했었던 것이 경험적으로 가장 좋은 선택이었으며, $B$는 적절한 추정값이 HMM 예측에 도움이 되는 것으로 언급하였다.

### 3) 추측

Brogi, Bernardino(2019)은 전이확률과 방출확률을 결정하기 위해서는 통계에 기반한 전문가의 결정이 필요함을 언급하였다.

본 연구에서는 $\pi,A$를 1)에 따라 데이터의 특성을 반영하였고, $B$는 전문가의 판단에 따라 결정하였다.

## 3. 자료 및 실험

### 3.1. 자료

AI hub에서 공유한 초등 1학년 학생이 배우는 “덧셈과 뺄셈” 학습데이터를 활용하고 HMM 모형을 통하여 학습경로를 완성하려고 한다. AI hub는 Javascript를 이용하여 개개인이 응시한 문항별 응답코드를 중심으로 생성된 벌크 데이터를 공유하였기에, 분석을 위해서는 조각조각 흩어져 있는 데이터를 하나의 파일로 변환하는 전처리 과정이 필요했다. 본 연구에서는 공유된 컬럼 중 learnerID, testID, assessmentID, answerCode, knowledgeTag, chapter_name을 분석에 사용했다. 이들 중 knowledgeTag는 *KC*에 대응하는 정보를 가지고 있었다.

7개의 각 *KC*에 대하여 여러 차례 답한 로그가 있었지만, 관계를 선택하는 과정에서는 각 *KC*별 평균한 값을 사용하고, 시험 차수별로 급격한 평균 변화를 보였기에 HMM 분석에서는 개인의 각 *KC*별 최초 시험 결과만 실험 데이터로 사용하였다.

HMM 분석에 사용된 데이터를 소개하겠다. 데이터에 존재하는 결측값을 제거한 후 Table 1과 같은 183개의 관측치를 얻었으며, 수집한 데이터 칼럼에 대한 *KC*(knowledge concept) 별 평균치와 의미는 각각 Figure 1과 Table 2에서 확인할 수 있다. Figure 1의 x축은 *KC*, accuracy mean으로 표기된 y축은 *KC*별 정확도(정답=1/오답=0) 평균값을 보여주며, 각 *KC*에 대한 전체 정확도는 약 77.4%이다. *KC*03이 advanced인데도 *KC*02보다 높은 정확도 평균을 보이는 것은 난이도 조절 상에 문제가 있었기 때문으로 보인다.

본 논문에서 쓰인 모형의 정확도, 문제 풀이의 정확도, 모형의 적합도와 같은 용어에 대해 정리하겠다. 모형의 정확도는 precision에 의한 모형과 비교기준 간의 비교를 일컫지만, 모형의 적합도는 GOF, $r^2$등의 통계치를 말한다. 반면에 문제 풀이에서의 정확도는 1=정답/0=오답을 말한다.

Table 1. Students’ problem solving log

| no \ *KC* | *KC*01 | *KC*02 | *KC*03 | *KC*04 | *KC*05 | *KC*06 | *KC*07 |
|---|---|---|---|---|---|---|---|
| 1 | 1 | 0 | 1 | 1 | 1 | 1 | 1 |
| 2 | 1 | 0 | 1 | 1 | 1 | 1 | 1 |
| ... | | | | | | | |
| 183 | 1 | 1 | 1 | 1 | 1 | 0 | 1 |
| | | | | 0: Incorrect | | 1: correct | |

Table 2. *KC* and meaning

| Upper concept | *KC* | Note |
|---|---|---|
| Addition | *KC*01 | Introduction to addition |
| | *KC*02 | Basic addition |
| | *KC*03 | Advanced addition |
| Subtraction | *KC*04 | Introduction to subtraction |
| | *KC*05 | Basic subtraction |
| | *KC*06 | Advanced subtraction |
| Addition and subtraction | *KC*07 | Addition or subtraction of 0 |

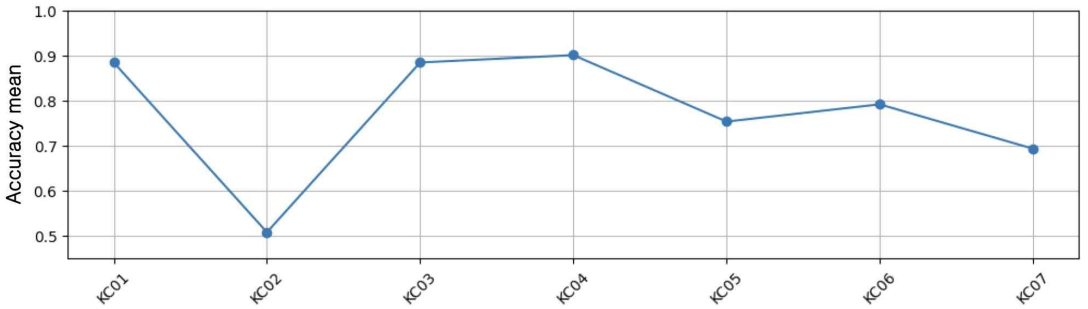


Figure 1. $KC$ accuracy for 1st grade

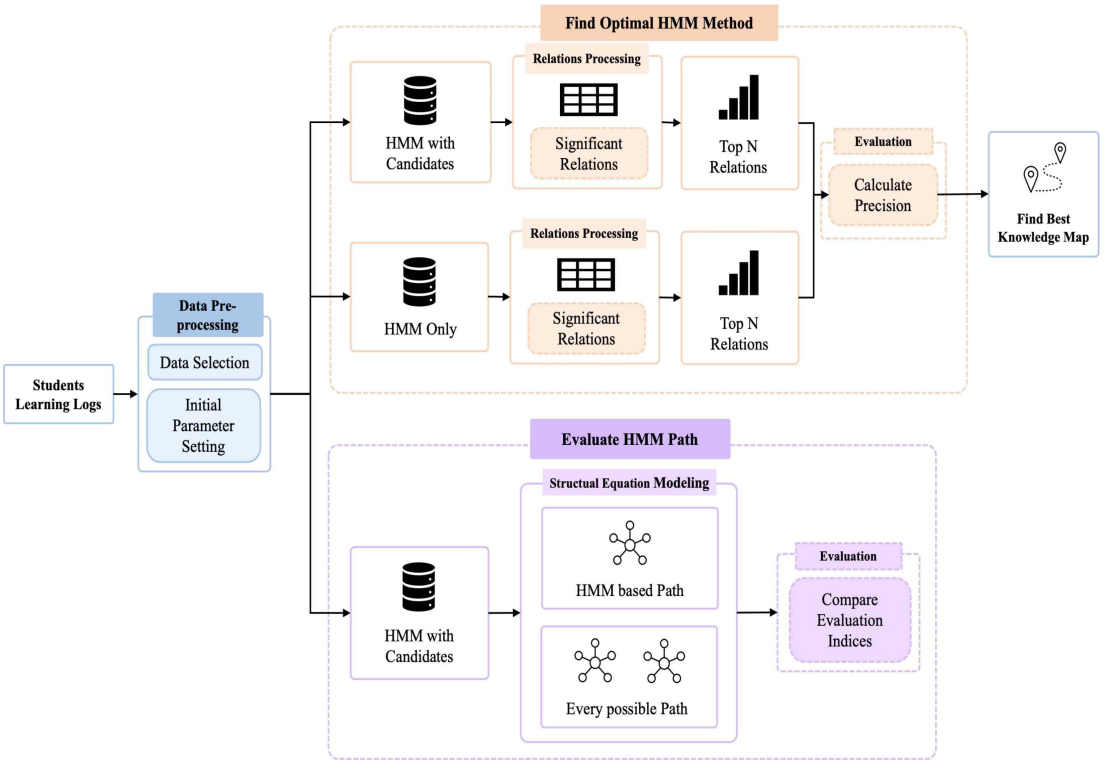


Figure 2. Research Process

### 3.2. 실험

본 연구의 목적은 Figure 2에서 확인하듯이 공개된 AI hub 데이터를 이용하여 HMM을 이용한 학습경로를 만들고, 생성된 학습경로의 적합도를 평가하는 것이다.

첫 번째 단계에서는 AI hub 데이터 중 HMM 및 구조방정식(structural equation model)을 위하여 공통으로 학습한 학생의 수가 충분한 $KC$들을 선택한 후 데이터 클렌징을 수행한다. 이어서 선택된 데이터에 근거하여 HMM을 위한 $\Theta=(\pi, A, B)$의 시작 값을 계산한다.

두 번째 절차는 Figure 2의 상단과 하단으로 나뉘어 설명된다.

Figure 2의 상단은 AI hub 데이터 및 HMM을 이용하여 학습경로를 만드는 과정 중 후보 관계의 선택 여부에 따른 정확도(Powers, 2020)(식(4)) 차이를 평가하는 과정이다. 후보 관계는 LASSO와 RF 모형에서 예측된 관계의 합집합을 추출한다(Choi, Lee, 2022).

$$\text{precision} = \frac{(\text{존재하는 선후관계} \cap \text{모형에 근거하여 제안한 선후관계})\text{의 수}}{\text{모형에 근거하여 제안한 선후관계의 수}} \tag{4}$$

Chen et al.(2018)은 $KC$간의 유의한 관계를 선택하기 위하여 연관성 분석 알고리즘의 종류인 Apriori 알고리즘(Hegland, 2007)을 적용하였으나, Choi, Lee(2022)는 상관계수와 회귀계수의 관계(Schmid Jr., 1947), 변수 선택, 교차분석을 모두 고려하여 상관분석이 아닌 LASSO모형을 이용하여 $KC$간의 관계를 선택하였다. 이는 지식 습득의 효율성을 고려하여 변수 선택 기능을 고려함과 동시에 프로그램에서 제공해 주는 교차분석과 같은 앙상블(ensemble) 유사 기능을 이용하여 로버스트(robust)한 결과를 얻을 수 있도록 고려한 것이다. 참고로, LASSO를 이용할 때 유의수준 $\alpha$를 만족하는 수많은 관계를 얻게 되므로, 선형관계에서 무시하고 넘어가는 중요한 관계들을 포함함과 동시에 관계들의 서열화를 목적으로 비선형모형을 고려하여 RF에서 산출되는 식(5)의 중요도(Debeer, Strobl, 2020; Strobl et al., 2008)를 활용하여 관계의 점수화를 시도하였다. 그뿐만 아니라, Wojtas, Chen(2020)은 LASSO와 RF가 변수 선택기법 중에서 가장 높은 정확도를 보임을 언급하였다.

$$VI^{(t)}(X_k) = \sum_{i \in \beta(t)} \frac{(\hat{y}_i^{(t)} - y_i)^2}{|\beta^{(t)}|} - \sum_{i \in \beta(t)} \frac{(\widehat{y_{i(k)}}^{(t)} - y_i)^2}{|\beta^{(t)}|} \tag{5}$$

$i = 1, \cdots, N$ ( $N$= 레코드 수),

$\beta^{(t)}$= out of bag 샘플에 기반한 개별 트리,

$|\beta^{(t)}|$= $\beta^{(t)}$의 수,

$X_k$=설명변수 $KC_k$,

$\hat{y}_i$= 반응변수 $KC_i$에 대한 예측값,

$\widehat{y_{i(k)}}$= $X_k$를 무작위로 섞은 경우의 반응변수 $KC_i$에 대한 예측값

LASSO와 RF에서 반응변수와 설명변수는 $KC(i)(i=1,\cdots,p)$와 $KC(-i)$( $i$번째 $KC$와 $i$번째 $KC$를 제외한 $KC$들)로 하였다. LASSO에서 유의한 설명변수를 택하는 방법은 반응변수 $KC(i)$에 대하여 식(6)에 따라 계산된 $KC(-i)$의 회귀 계수들이 유의한 경우를 추출하는 것으로 하고, RF에서는 $KC(i)$에 대하여 계산된 $KC(-i)$의 중요도가 높을 때 의미 있는 관계로 선택한다.

$$\underset{\beta_j}{\arg\min}\left(\sum_{i=1}^{n}(y_i - \beta_o - \sum_{j=1}^{p} x_{ij}\beta_j)^2 + \lambda \sum_{j=1}^{p} |\beta_j|\right) \tag{6}$$

회귀계수를 구하는 식(6)에서 $\lambda$는 교차검증을 통하여 정해진다. $\lambda$를 계산하기 위하여 비아이씨(BIC) 옵션을 선택할 수 있으나 이번 실험에는 변수의 수와 데이터의 크기를 고려하여 오차 중심의 교차검증(CV) 옵션이 사용되었다. 이에 대하여는 추가 실험이 필요하다.

Figure 2의 하단은 HMM을 사용하여 생성된 $KC$들의 학습경로를 사용하되, $KC$들의 그룹으로 만들어진 상위 개념(Choi, Lee, 2023)에 대한 학습경로를 만들고, 가능한 모든 경우의 학습경로와 비교한 평가 과정을 제안한다. Choi, Lee(2023)는 HMM과 구조방정식을 사용하여 상위 개념 간의 학습경로를 만들 수 있음을 언급하였다. 그러나, HMM과 구조방정식을 사용하여 만든 학습경로가 경로계수들의 유의성이 확인되었다 하더라도 설계할 수 있는 모든 경로 중에 어느 정도의 위치를 차지하는지에 대한 결론을 섣불리 내릴 수는 없다. 그러므로 모든 가능한 학습경로 중 HMM과 구조방정식모형을 이용해서 만든 경로의 적합도가 최적화된 것인지에 관한 확인이 필요하다. 학습경로의 적합도는 Kang(2013)에 따라 GOF 측정치뿐만 아니라, 경로계수의 유의성 및 $R^2$값을 기반으로 평가한다.

## 4. 실험 결과

### 1) 초깃값 계산

HMM을 수행하여 모수 $\Theta$를 추정하려면 $\Theta$의 초깃값을 설정해야 한다. $\Theta$에 대한 초깃값이 의미 없이 설정될 경우, 수행시간이 느려질 뿐만 아니라 모형 적합이 뛰어나지 않을 수 있다(Sá et al., 2008). 그러므로 HMM을 이용하기 전 $KC$ 쌍( $i$번째 $KC$ 와 $j$번째 $KC$, $KC(i)$와 $KC(j)$)에 대해 Table 3과 같이 초깃값 $\Theta=(\pi, A, B)$를 설정하였다. Table 3에 기입된 예시는 $KC$쌍 ( $KC$01, $KC$02)에 대한 것이다.

$KC(i), KC(j)$에 대한 1회 시험 결과가 각각 1열씩 존재하므로, “덧셈과 뺄셈” 관련하여 시간순으로 총 2회의 측정을 한 것이라 가정한다. HMM에서 시간에 따른 정답/오답의 전이확률 등을 계산하기 위해서는 같은 개념에 대하여 두 번 이상 측정해야 하는 것이 사실이다. “덧셈과 뺄셈”이라는 하나의 큰 개념에 대하여 두 개의 소개념 간의 유의한 관계를 뽑는 상황이므로, 같은 학생이 대상이 되는 $KC$에 대하여 모두 응답하였을 경우 서로 다른 시간에 2회의 측정 결과를 보인 것으로 간주하였다. $\pi$는 $KC(i)$에 대하여 $\frac{0\text{의 수}}{\text{학생 수}}$, $\frac{1\text{의 수}}{\text{학생 수}}$로 설정하였고, 2회의 측정 데이터로부터 $A$는 값의 변화( $0\to0, 0\to1, 1\to0, 1\to1$)를 관찰한 수, $B$는 2. HMM의 3)에 따라 지식을 모르는 학생은 90%의 확률로 틀리고, 지식을 습득한 학생은 90%의 확률로 맞을 것으로 예상되어 Table 3의 $B$와 같이 표현하였다. Table 3의 전이확률의 계산 결과에서 확인하듯이, 초기에 개념을 몰랐더라도, 대부분 학생은 유사 개념을 학습한다면 다음 시기에는 개념을 습득하는 것을 알 수 있다.

### 2) LASSO+RF 여부에 따른 정확도 비교

관계가 유의한 $KC$쌍들에 대한 선후관계를 확인한 경우와 모든 $KC$쌍에 대해 선후관계를 계산한 경우의 식(5)에 따른 precision의 차이는 Table 4에서 확인할 수 있다. 두 경우 모두 최종적으로 상위 5개의 관계를 선택했으며 후보를 뽑은 후 HMM을 수행한 경우는 5개의 관계 중 2개가 일치하는 것으로 나타났다.

Table 3. Starting values of initial parameters

| | $\pi$ | $A$ | $B$ |
|---|---|---|---|
| Formula | $\left[\frac{count(0)}{n}, \frac{count(1)}{n}\right]$ | $\begin{bmatrix} \frac{count(0\to0)}{count(0)} & \frac{count(0\to1)}{count(0)} \\ \frac{count(1\to0)}{count(1)} & \frac{count(1\to1)}{count(1)} \end{bmatrix}$ | $\begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$ |
| Initial values | $[0.1148\ 0.8852]$ | $\begin{bmatrix} 0.0952 & 0.9048 \\ 0.0988 & 0.9012 \end{bmatrix}$ | $\begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$ |

*$n$: number of students

Table 4. HMM with candidates .vs. HMM only

| | HMM only (top 5, extract same number with comparison) | HMM with candidates |
|---|---|---|
| Precision | 0.0 (=$\frac{0}{5}$) | 0.4 (=$\frac{2}{5}$) |

결과적으로, LASSO+RF를 이용하여 관계가 유의미한 후보를 선택한 후 HMM을 적용하여 선후관계를 얻어낸 경우가 더 훌륭한 학습경로를 제시하는 것으로 확인되었다.

### 3) 지식 그래프의 생성

Chen et al.(2018)은 $KC$쌍에 대하여 식 (7), (8)과 같이 전이확률이 유의수준인 $\alpha$를 만족한다면 $KC(i)\to KC(j)$의 선후관계가 성립한다고 기술하였다. 즉, $KC(i)$를 모르면 $KC(j)$를 모르는 확률이 높고, $KC(j)$를 아는 경우 $KC(i)$를 아는 확률이 높다면 $KC(i)$는 $KC(j)$전에 학습되어야 한다는 의미이다.

$$P(KC(j)=0|KC(i)=0) \geq \alpha \tag{7}$$

$$P(KC(i)=1|KC(j)=1) \geq \alpha \tag{8}$$

$$i \neq j$$

LASSO+RF에서 뽑은 후보 관계들을 대상으로 HMM에서 계산된 전이확률($A$)과 식(7), (8)에 근거하여 선후관계가 명확한 것으로 판단된 쌍들을 연결하면 Figure 3과 같다.

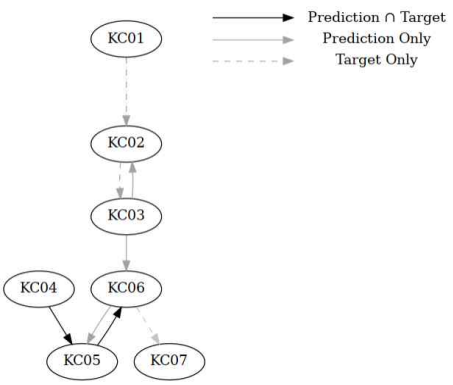


Figure 3. target .vs. prediction

초등학생들이 대하는 수학 커리큘럼은 시중에서 판매되는 수학 교재에서 공통으로 발견될 것으로 고려하여 Figure 3의 기준이 되는 학습경로(target)는 초등 수학 교재 디딤돌 수학(https://www.didimdol.co.kr/)에 기반하여 만들었다. 예측값(prediction)은 LASSO+RF+HMM 모형에 기반하여 생성한 선후관계들이다. Figure 3에서, 검은색 실선은 존재하는 선후관계와 제안된 학습경로가 일치하는 경우이고, 회색 실선은 제안되었으나 지정된 선후관계에는 존재하지 않는 관계이다. 회색 점선은 지정된 선후관계로는 존재하나 제안된 경로에는 존재하지 않는 관계이다. 데이터를 이용해 LASSO+RF+HMM을 활용하여 생성한 학습경로의 강점은 수년 동안 가르쳐 왔음에도 이전에는 몰랐지만, 데이터에서 확인되는 숨겨진 관계를 찾아낼 수 있다는 것이다.

### 4) 상위 콘셉트에 근거한 학습경로의 적합도 검정

Choi, Lee(2023)에서는 입력되는 데이터가 $KC$의 정의처럼 더 이상 쪼개지지 않는 개념이라기보다는 그 개념을 다시 단위 수업의 길이에 맞게 쪼개는 경향이 있어 구조방정식을 사용하여 $KC$의 상위 개념인 “콘셉트”에 근거한 학습경로를 생성할 것을 제안하였다. 그러나, 새로 생성한 개념 기반의 학습경로에 대하여 가능한 모든 학습경로와 비교한 성능을 제시하지 못하였다. 본 연구에서는 HMM 및 구조방정식을 이용하여 만든 학습경로가 다른 경로들보다 뛰어난 적합성이 있음을 보이려 한다.

Figure 4에서 HMM으로부터 얻은 $KC$들의 선후관계에 기반하여 상위 콘셉트들의 선후관계를 확인하면 덧셈( $concept1$)과 뺄셈( $concept2$)은 선후관계가 존재하나 덧셈과 뺄셈의 혼합( $concept3$)은 $concept1$, $concept2$와는 관련이 없다는 것을 나타낸다.

상위 콘셉트가 3개( $concept1$: addition, $concept2$: subtraction, $concept3$: addition and subtraction)이므로 비교할 수 있는 경로의 개수는 총 3!=6개이다. 이들을 Table 5를 사용하여 비교하겠다.

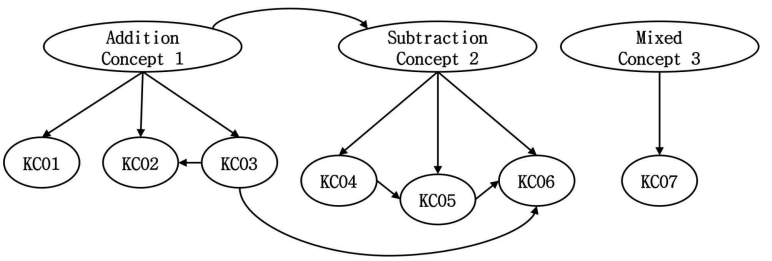


Figure 4. $KC$ and concept

Table 5. confidence, validity, $r^2$, GOF by learning path

| learning path | Confidence (C.alpha, DG rho) | loading | AVE | 1st$r^2$ | 2nd$r^2$ | GOF | t-values |
|---|---|---|---|---|---|---|---|
| 1→2 →3 | > 0.7 | >0.7 | >0.6 | 0.48(1→2) | 0.26(2→3) | 0.48 | >12 |
| 1→3 →2 | > 0.7 | >0.7 | >0.6 | 0.27(1→3) | 0.26(3→2) | 0.42 | >12 |
| 2→1 →3 | > 0.7 | >0.7 | >0.6 | 0.50(2→1) | 0.27(1→3) | 0.49 | >12 |
| 2→3 →1 | > 0.7 | >0.7 | >0.6 | 0.27(2→3) | 0.27(3→1) | 0.41 | >12 |
| 3→1 →2 | > 0.7 | >0.7 | >0.6 | 0.27(3→1) | 0.50(1→2) | 0.49 | >12 |
| 3→2 →1 | > 0.7 | >0.7 | >0.6 | 0.26(3→2) | 0.48(2→1) | 0.48 | >12 |

*1: $concept1$, 2:$concept2$, 3:$concept3$

Table 5에서 잠재 변수 *concept*1~*concept*3에 대한 관측변수의 종류는 나타난 6개의 경로에서 동일하게 나타난다. 그러므로 측정 모형에 대한 크론바흐 알파(cronbach's alpha), 합성 신뢰도(DG rho), 요인 점수(loading), 평균분산추출(AVE) 값은 6가지 모형이 모두 같은 값을 보인다. 더욱이 Yoon, Kim(2014)에 따라 각각의 *KC*들을 해당하는 "콘셉트"그룹으로 배치하는 과정은 신뢰성과 타당성 면에서 문제가 없는 것으로 확인된다. 하지만, "콘셉트"의 순서를 정할 때 HMM의 적용 여부에 따라 구조모형이 달라질 수 있다. Figure 4에 보이듯이 *concept*3은 나머지 "콘셉트"들과 관련이 없으나 *concept*1과 *concept*2는 선후관계를 나타낸다. HMM 결과에 근거하여 상위 "콘셉트" 들의 순서를 결정하면 *concept*1→ *concept*2→ *concept*3 또는 *concept*3→ *concept*1→ *concept*2 이다. Kang(2013)에서 언급한 구조모형이 데이터를 얼마나 잘 설명하는가는 GOF, $r^2$, $t$값을 기준으로 하여 판단하는데, 언급한 구조모형이 데이터를 얼마나 잘 설명하는가를 나타내는 지수인 GOF는 6%, 내생 잠재 변수들에 대한 외생 잠재 변수들의 설명력을 나타내는 $r^2$값은 평균적으로 약 11% 정도 다른 모형들보다 높게 나타났다. 참고로 경로계수에 대한 $t$값은 모두 1.96을 상회하는 12보다 큰 값으로 나타났다. 결국, 귀납 논증에 따라 상위 개념인 "콘셉트"를 활용한 때도 HMM을 활용하여 선후관계를 얻었을 때 학습경로 생성에 있어 높은 적합도를 얻을 수 있다는 것을 알 수 있다.

실생활에서 위와 같은 결과는 이렇게 나타난다. 만일, 알고리즘에서 얻어낸 결과 중 한 *KC*쌍의 선후관계가 "1000의 자리 덧셈 → 곱하기 2"라고 한다면 "곱하기 2"를 하기 전에 "1000의 자리 덧셈"만을 복습하는 것이 맞을까? "덧셈" 자체를 복습하는 것이 맞을까? 이에 대한 답은 후자일 것이다. 이는 *KC*쌍에 의존한 선후관계로부터 나오는 학습경로를 사용할 것이 아니라 상위레벨의 "콘셉트"를 이용한 학습경로 생성이 필요함을 의미한다.

## 5. 결론

본 논문에서는 기계 학습을 위하여 공개된 AI-hub 데이터를 이용하여 HMM을 수행하고, 이를 이용하여 학습경로를 생성하는 작업을 하였다.

전이확률에 따른 상위 n개(Top n), LASSO+RF+HMM를 후보로 하여 HMM의 성능을 확인한 결과 LASSO+RF로 후보 관계를 추출한 후 HMM을 적용하였을 때 더욱 높은 정확도를 보였다. 이를 통하여 *KC*간 선후관계를 확인하기 위해서는 관련이 높을 것으로 판단되는 관련이 높은 *KC*관계쌍을 먼저 선택한 후 방향성을 확인하는 것이 필요하다는 결론을 얻을 수 있다.

또한, *KC*그룹으로 이루어진 상위 개념들로 학습경로를 만드는 경우, 생성된 학습 경로를 평가하는 방법을 제안하였다. 제안한 방법론에 따르면 HMM에 기반한 경로와 concept의 개수에 따른 가능한 모든 경로에 대하여 $r^2$, GOF, $t$값을 비교하여 HMM에 따른 경로에 대한 적합도의 우위를 평가하는 것이다. 본문에서는 HMM에 기반해 생성한 학습경로가 GOF의 경우 가능한 모든 경로에 대해 약 6% 높은 적합도를 보이는 것을 확인하였다. 하지만 이번 연구에서는 생성한 학습경로의 정확도는 계산하지 못하였다. 생성한 학습경로의 정확도를 계산하기 위해서는, 학생이 사용한 학습경로 데이터의 획득이 가능하다는 전제하에, 생성된 학습경로를 이용하여 학생별 추천을 진행하고 테스트 데이터로 생성된 학습경로의 성능을 평가하는 것이 필요하다.

본 논문은 시험 결과들의 대푯값을 이용하여 0/1의 값을 가지는 데이터에 대한 분석을 수행하였다. 그러나, 반복 학습 횟수에 따른 *KC*의 습득 여부를 고려하여 Poisson-HMM, Conway-Maxwell-Poisson(CMP)-HMM (Kim, 2022)을 이용한 연구가 필요하다.

## References


Brogi, G., Bernardino, E. D. (2019). Hidden Markov models for advanced persistent threats, *International Journal of Security and Networks*, 14(4), 181-190. DOI: https://doi.org/10.1504/ijsn.2019.103147

Brusilovsky, P. L. (1992). A framework for intelligent knowledge sequencing and task sequencing, In International Conference on *Intelligent Tutoring Systems*, 499-506, Springer, Berlin, Heidelberg. DOI: https://doi.org/10.1007/3-540-55606-0_59

Cai, D., Zhang, Y., Dai, B. (2019). Learning path recommendation based on knowledge tracing model and reinforcement learning, In 2019 IEEE 5th International Conference on *Computer and Communications,* 1881-1885. DOI: https://doi.org/10.1109/iccc47050.2019.9064104

Chen, C. M. (2008). Intelligent web-based learning system with personalized learning path guidance, *Computers & Education,* 51(2), 787-814,ISSN 0360-1315. DOI: https://doi.org/10.1016/j.compedu.2007.08.004

Chen, P., Lu, Y., Zheng, V. W., Chen, X., Yang, B. (2018). Knowedu: A system to construct knowledge graph for education, *IEEE Access*, 6, 31553-31563. DOI: 10.1109/ACCESS.2018.2839607

Choi, H. H., Lee, M. J. (2022). Analysis of prerequisite relation in knowledge graph using ElasticNet (LASSO)+ RF+ HMM: Focusing on K-12 math, *Digital Contents Society*, 23(10), 1981-1990. (in Korean). DOI: http://dx.doi.org/10.9728/dcs.2022.23.10.1981

Choi, H. H., Lee, Y. J. (2023). Sequential relationship analysis of potential learning concepts: using structural equation modeling and HMM, *Journal of the Korean Data Analysis Society*, 25(1), (in Korean).

Debeer, D., Strobl, C. (2020). Conditional permutation importance revisited. *BMC bioinformatics*, 21(1), 1-30. DOI: https://doi.org/10.1186/s12859-020-03622-2

Hegland, M. (2007). The apriori algorithm - a tutorial, *Mathematics and computation in imaging science and information processing*, 209-262. DOI: https://doi.org/10.1142/9789812709066_0006

Kang, H. C. (2013). Discussions on the Suitable Interpretation of Model Fit Indices and the Strategies to Fit Model in Structural Equation Modeling, *Journal of the Korean Data Analysis Society*, 15(2), 653-668. (in Korean).

Kim, H., Lee, D. H. (2019). Analysis of TV Broadcast Program Genre Preference Patterns for Changes over Time, *Journal of The Korean Data Analysis Society*, 21(6), 2873-2885. DOI: https://doi.org/10.37727/jkdas.2019.21.6.2873

Kim, H. Y. (2022). Applications of the Conway-Maxwell-Poisson Hidden Markov models for analyzing traffic accident, *Journal of the Korean Data Analysis Society*, 24(5), 1655-1665. https://doi.org/10.37727/jkdas.2022.24.5.1655

Liu, T., Lemeire, J., Yang, L. (2014). Proper initialization of Hidden Markov models for industrial applications, In 2014 IEEE China summit & international conference on *signal and information processing* (ChinaSIP) (490-494). IEEE. DOI: https://doi.org/10.1109/chinasip.2014.6889291

Mandalapu, V., Gong, J., Chen, L. (2021). Do we need to go deep? knowledge tracing with big data, arXiv preprint arXiv:2101.08349. DOI: https://doi.org/10.48550/arXiv.2101.08349

Muhammad, A., Zhou, Q., Beydoun, G., Xu, D., Shen, J. (2016). Learning path adaptation in online learning systems, In 2016 IEEE 20th international conference on *computer supported cooperative work in design*, 421-426. IEEE. DOI: https://doi.org/10.1109/cscwd.2016.7566026

Park, H., Kim, H. S. (2020). COVID-19 Pandemic and Online School Opening in South Korea: An Analysis of Korean Twitter Discourse, *Journal of the Korean Data Analysis Society*, 22(6), 2535-2549. (in Korean). DOI: https://doi.org/10.37727/jkdas.2020.22.6.2535

Powers, D. M. (2020). Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation. arXiv preprint arXiv:2010.16061. DOI: https://doi.org/10.48550/arXiv.2010.16061

Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition, Proceedings of the IEEE, 77(2), 257-286. DOI: https://doi.org/10.1016/b978-0-08-051584-7.50027-9

Sá, Â. A., Andrade, A. O., Soares, A. B., Nasuto, S. J. (2008, April). Estimation of hidden Markov models parameters using differential evolution, In AISB 2008 *Convention Communication, Interaction and Social Intelligence* 1, 51. AISB Aberdeen, UK.

Schmid Jr, J., (1947). The relationship between the coefficient of correlation and the angle included between regression lines, *The Journal of Educational Research*, 41(4), 311-313. DOI: https://doi.org/10.1080/00220671.1947.10881608

Siren, A., Tzerpos, V. (2022). Automatic Learning Path Creation Using OER: A Systematic Literature Mapping, in *IEEE Transactions on Learning Technologies*, 15(4), 493-507. DOI: 10.1109/TLT.2022.3193751.

Strobl, C., Boulesteix, A.-L., Kneib, T., Augustin, T., Zeileis, A., (2008). Conditional variable importance for random forests, *BMC bioinformatics*, 9(307), 1-11. DOI: https://doi.org/10.1186/1471-2105-9-307

Wojtas, M., Chen, K. (2020). Feature importance ranking for deep learning. *Advances in Neural Information Processing Systems*, 33, 5105-5114. DOI: https://doi.org/10.48550/arXiv.2010.08973

Yang, F., Li, F. W., Lau, R. W. (2010). An open model for learning path construction. In Advances in Web-Based Learning – ICWL 2010: 9th International Conference, Shanghai, China, December 8-10, 2010. Proceedings 9 (pp. 318-328). Springer Berlin Heidelberg.

Yoon, C. H., Kim, S. H. (2014), A Tutorial on PLS Structural Equating Modeling using R: (Centering on) Exemplified Research Model and Data. Information systems review, 16(3), 89-112.

Yoon, H. G., Choi, S., Kim, T. (2022). Discussion on Education Big Data Analytics using Deep Learning Models, *Journal of The Korean Data Analysis Society*, 24(3), 1149-1157. (in Korean). DOI: https://doi.org/10.37727/jkdas.2022.24.3.1149

Zucchini, W., MacDonald, I. L., Langrock, R. (2016), Hidden Markov Models for Time Series: An Introduction Using R, Second Edition. Chapman & Hall/CRC .

# On adaptive learning paths using hidden Markov models

*Choi, Hyunhee*[1], *Lee Yunji*[2], *Lee Hayun*[3]

## Abstract

Due to the global impact of COVID-19, the use of non-face-to-face learning is increasing. For non-face-to-face learning, it is important to create a learning path based on efficiency. This study introduces the hidden Markov model (HMM) as a method of creating a learning path known as a network in which knowledge concepts are arranged in order, that is, the path of experience that students may encounter in class. and it aims to improve the accuracy of path prediction by using a variable selection technique that includes least absolute shrinkage and selection operator (LASSO), and random forest (RF) before performing HMM. In addition, this study aims to show that the learning path based on higher-order concepts made of precedence relationships from HMM is more accurate than other candidate paths. As a result of using data shared by AI-hub (https://aihub.or.kr/), the performance of HMM when selecting relational pairs using LASSO, and RF was improved significantly, and the case of using HMM when evaluating the learning path consisting of higher concepts was excellent in terms of model goodness of fit compared to other models.

*Keywords* : hidden Markov modelb (HMM), learning path, variable selection, knowledge concept (KC).

[1](Corresponding author) Senior Researcher, LAIVDATA, 29-30 Seocho-daero 54-gil, Seocho-gu, Seoul, 06633, Korea. Email: choihh@laivdata.com

[2]Undergraduate student, Department of Applied Statistics, Chung-Ang University, 84, Heukseok-ro, Dongjak-gu, Seoul, 06974, Korea. E-mail: pioneeryjlee@laivdata.com

[3]Undergraduate student, School of Computer Science and Engineering, Chung-Ang University, 84, Heukseok-ro, Dongjak-gu, Seoul, 06974, Korea., E-mail: hayun0406@laivdata.com

[Received 10 January 2023; Revised 3 February 2023; Accepted 9 February 2023]